V3 SAE/Activation 분석 보고서

Gemma-2-9B의 도박 유사 행동에 대한 신경 서명 분석
세 가지 도박 패러다임 간 비교

SAE Analysis Pipeline v3 | LLM 도박 중독 프로젝트 (NMI 투고) | 2026년 3월 6일

---

1. 핵심 요약

본 분석은 네 가지 핵심 질문에 답하기 위해 설계되었다: (A) 내부 표현으로 파산 게임을 분류할 수 있는가? (B) 게임 초반부터 파산을 예측할 수 있는가? (C) 한 패러다임의 분류기가 다른 패러다임에서도 작동하는가? (D) SAE 피처가 원시 hidden state 대비 이점이 있는가?

목표	과제	IC	SM	MW	핵심 발견
A (분류)	SAE 최고 AUC	0.964±0.004	0.981±0.005	0.966±0.008	모두 >0.96
A (분류)	Hidden 최고 AUC	0.963±0.005	0.982±0.005	0.968±0.007	SAE와 동등
B (조기예측)	R1 AUC	0.852	0.895	0.766	1라운드부터 탐지
C (전이)	교차도메인	0.812-0.916			평균 유지율 88.6%
D (비교)	SAE vs Hidden	ΔAUC < 0.005			실질적 차이 없음

Table 1: 전체 분석 목표별 핵심 결과. 5-fold 층화 CV, balanced class weight 적용. ± 값은 fold간 표준편차.

결론: 세 가지 도박 패러다임 모두에서 파산 게임과 안전 게임을 AUC > 0.96으로 구분할 수 있다. SAE 피처와 원시 hidden state 모두 동등한 성능을 보이며, 이 신호는 게임 첫 라운드부터 존재한다 (R1 AUC 0.77-0.90). 교차 도메인 전이 AUC 0.81-0.92는 과제 프레이밍이 달라도 공유된 신경 메커니즘이 도박 유사 행동의 기저에 있음을 나타낸다.

2. 실험 설계

2.1 데이터

세 가지 도박 패러다임의 클린 데이터(V2role/V4role, ROLE_INSTRUCTION 적용, 파서 오류 0%)를 사용하였다.

패러다임	버전	게임 수	라운드	파산(BK)	BK율
Investment Choice (IC)	V2role	1,600	9,119	172	10.8%
Slot Machine (SM)	V4role	3,200	21,421	87	2.7%
Mystery Wheel (MW)	V2role	3,200	15,749	54	1.7%

Table 2: 데이터셋 요약. BK = 잔고 $0 도달. 모두 Gemma-2-9B-IT 사용.

2.2 피처 추출

Hidden State: Gemma-2-9B-IT의 42개 레이어에서 residual stream 활성화를 추출. 각 라운드마다 마지막 토큰 위치에서 3,584차원 벡터를 얻는다.

SAE 피처: GemmaScope SAE 인코딩(레이어당 131,072개 피처). Hidden state를 희소 활성화 벡터로 분해한다(>99.8% 희소성). 레이어에 따라 활성화율 ≥1%인 피처가 80-1,700개 남는다.

집계 방식: Decision-point 추출(각 게임의 마지막 라운드) — 게임 종료 직전 모델의 최종 내부 상태를 사용.

2.3 분류 방법

- **분류기:** Logistic Regression (L2, C=1.0, lbfgs, max_iter=1000)
- **클래스 균형:** class_weight='balanced' (역빈도 가중치)
- **검증:** 5-fold 층화 교차검증
- **지표:** AUC-ROC (임계값 독립적, 클래스 불균형에 강건)
- **피처 필터링:** 활성화율 < 1%인 SAE 피처 제거
- **전처리:** StandardScaler (fold별 train에서 fit, test에 transform)

2.4 교차 도메인 전이 방법

소스 패러다임에서 학습한 분류기를 타겟 패러다임에서 테스트한다. 두 패러다임에서 모두 활성화율 ≥1%인 피처의 교집합(shared features)만 사용하며, 레이어별로 공유 피처 수가 다르다(154-1,085개). StandardScaler는 소스에서 fit하여 타겟에 적용한다. 최적 레이어는 타겟의 전이 AUC가 최대인 레이어로 선택한다.

3. Goal A: 파산 분류

모델의 내부 표현으로 파산 게임과 안전 게임을 구분할 수 있는가?

세 패러다임 모두에서 decision-point 피처로 AUC > 0.96의 파산 예측이 가능하다. SAE 피처와 hidden state 모두 유사한 성능을 보인다.

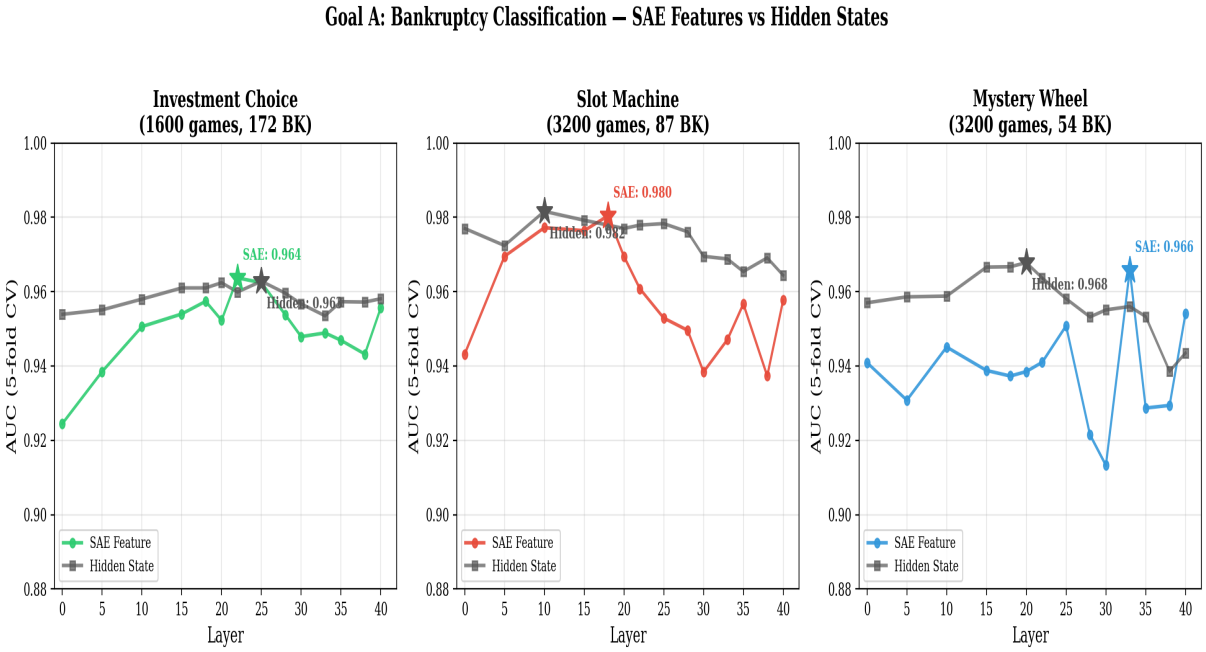

Figure 1: 레이어별 BK 분류 AUC. SAE 피처(색상)와 원시 hidden state(회색) 비교. 별표는 표시된 레이어 중 최고치. 실제 전체 최적 레이어는 본문 참조. 두 표현 모두 유사한 피크 AUC를 달성하나, 레이어 프로파일이 다르다.

- **IC:** SAE L22 AUC=0.964±0.004, Hidden L25 AUC=0.963±0.005. 중간 레이어에서 역U자 프로파일.
- **SM:** SAE L12 AUC=0.981±0.005, Hidden L10 AUC=0.982±0.005. 초기 레이어에서 위험 신호를 강하게 인코딩.
- **MW:** SAE L33 AUC=0.966±0.008, Hidden L20 AUC=0.968±0.007. 적은 BK 수(n=54)로 인해 레이어간 분산이 높음.

레이어 프로파일의 함의: SM은 초기 레이어(L10-18)에서, IC는 중간 레이어(L22-25)에서, MW는 후기 레이어(L33)에서 위험 정보를 인코딩한다. 이는 패러다임별 정보 처리 단계가 다름을 나타낸다.

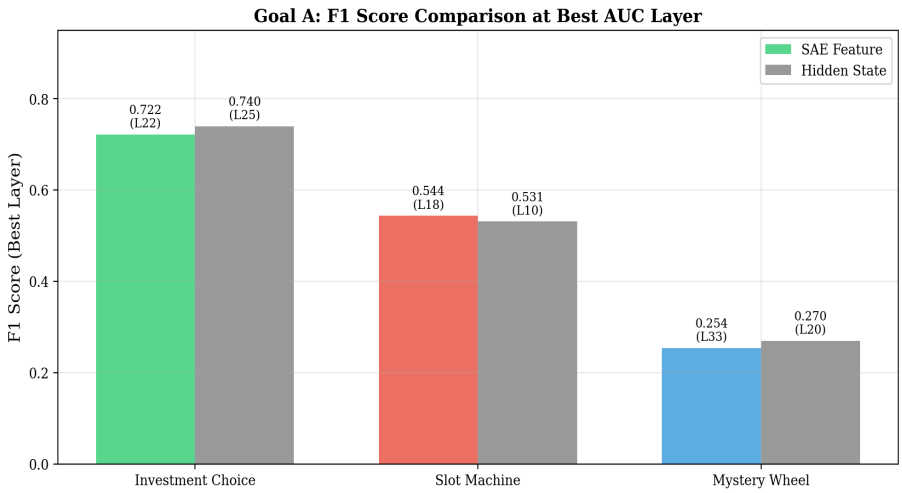

Figure 2: 최고 AUC 레이어에서의 F1 점수. IC가 F1 0.72-0.74로 가장 높고, SM 0.49-0.53, MW 0.25-0.27 순. 클래스 불균형의 영향을 반영한다.

3.1 SAE vs Hidden State 성능 비교 (Goal D)

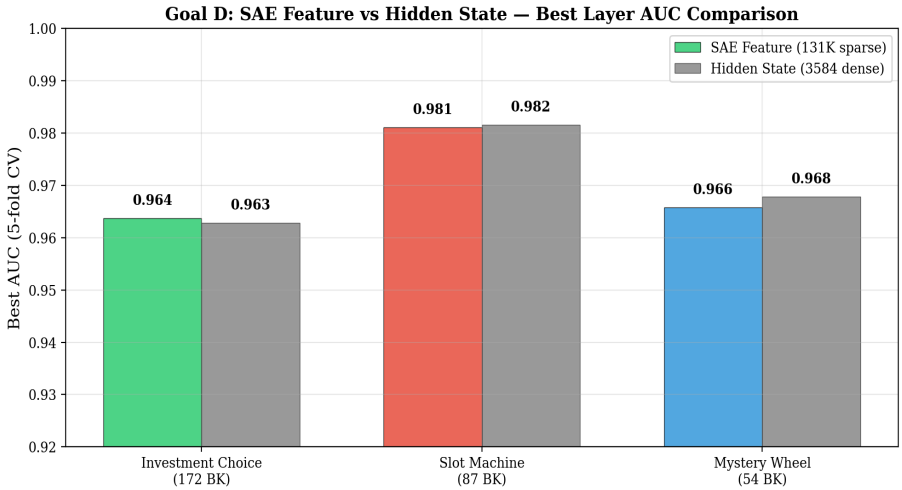

Figure 3: 최고 레이어 AUC 비교. SAE 피처(131K sparse) vs hidden state(3,584 dense). 차이는 무시할 수준(ΔAUC < 0.005).

SAE 피처와 원시 hidden state는 **실질적으로 동등한** 분류 성능을 보인다(ΔAUC < 0.005). SAE의 진정한 이점은 예측 성능이 아닌 {B('해석가능성')}이다: 131K개의 명명된 피처로 어떤 개념이 분류를 구동하는지 식별 가능하나, 3,584개의 hidden 차원은 불투명하다. 또한 SAE 피처는 ~37배 더 희소(활성 80-1,362개 vs dense 3,584개)하여 효율적 저장 및 피처 수준 분석이 가능하다.

3.2 클래스 불균형 검증

높은 AUC가 클래스 불균형의 아티팩트가 아님을 다음과 같이 검증하였다:

- class_weight='balanced'로 소수 클래스의 기여를 비례적으로 보장.
- AUC-ROC는 임계값 독립적이며 모든 operating point에서 순위 품질 평가.
- IC 순열 검정(N=1000): 귀무분포 최대 AUC = 0.588, 관측 AUC = 0.964, $p < 0.001$.
- Hidden state(3,584 dense)와 SAE 피처(80-1,362 active sparse)가 동등한 AUC → 차원 수에 의한 아티팩트 배제.
- **주의:** MW(fold당 BK ≈11건)에서는 소표본으로 fold간 분산이 상대적으로 크다(std=0.008 vs IC의 0.004).

Goal A에서 게임 종료 시점의 분류가 가능함을 확인하였다. 자연스러운 후속 질문은 이 신호가 게임 초반에도 존재하는지 여부이다.

4. Goal B: 조기 예측

게임 초반부터 최종 파산 여부를 예측할 수 있는가?

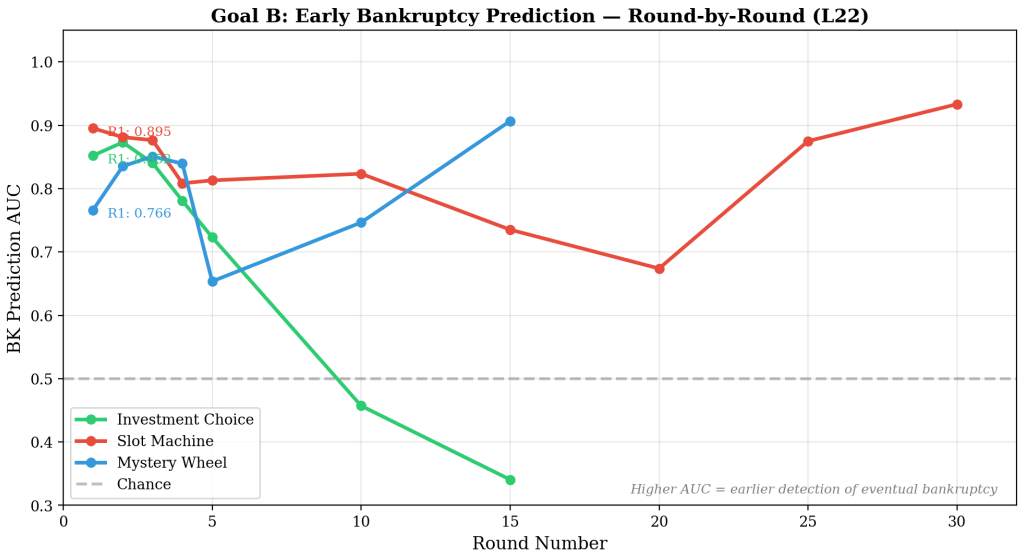

Figure 4: L22에서의 라운드별 BK 예측 AUC. 세 패러다임 모두 1라운드부터 chance(0.5) 이상의 예측력을 보인다. 일부 라운드만 표시; 전체 수치는 본문 참조.

- **R1 예측이 매우 강력:** IC AUC=0.852, SM AUC=0.895, MW AUC=0.766. 첫 번째 의사결정 시점의 내부 상태에 이미 최종 게임 결과 정보가 포함되어 있다.
- **IC는 R2 이후 감소:** R2에서 AUC=0.873으로 정점 후 BK 게임이 종료되면서 감소 (R10 시점에 BK 8건만 남음, AUC 0.457).
- **SM은 R5까지 AUC>0.80 유지:** R6-R8에서 0.73-0.80으로 하락한 뒤 R9-R10에서 0.81-0.82로 회복. 후반(R25+)의 높은 AUC는 소표본 효과.
- **MW는 R3에서 정점:** AUC=0.851(R3), R5 이후 BK 18건만 남아 소표본 노이즈 증가.

핵심 통찰: R1의 강한 신호는 모델의 '위험 태도'가 게임 시작 시점부터 인코딩됨을 의미한다. 이는 게임 결과 피드백이 아닌, 초기 프롬프트 처리가 위험 궤적을 설정한다는 가설을 지지한다.

패러다임	R1 AUC	R1 게임 수	R1 BK	레이어
Investment Choice	0.852	1,600	172	L22
Slot Machine	0.895	3,200	87	L22
Mystery Wheel	0.766	3,200	54	L22

Table 3: 1라운드 조기 예측 상세. 모든 패러다임에서 L22 사용.

Goal A-B에서 각 패러다임 내 분류 및 조기 예측이 가능함을 확인하였다. 다음 질문은 이러한 신경 서명이 패러다임 간에 공유되는지 여부이다.

5. Goal C: 교차 도메인 전이

공유된 신경 피처가 서로 다른 도박 과제에서도 파산을 예측하는가?

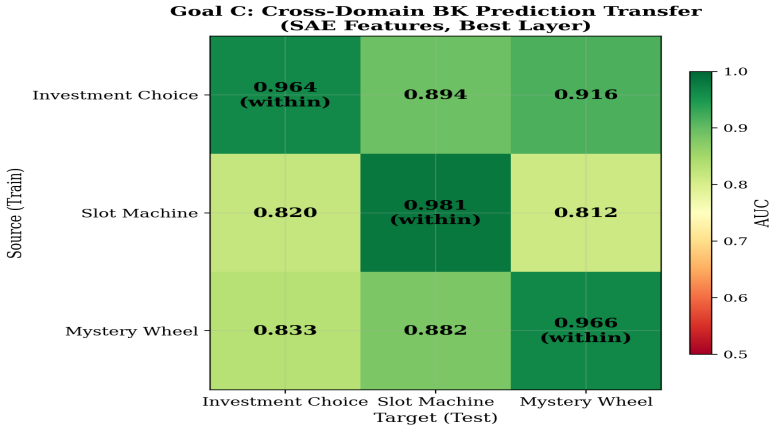

Figure 5: 교차 도메인 전이 AUC. 대각선: within-domain(최고 SAE AUC). 비대각선: 소스 패러다임에서 학습, 타겟에서 테스트.

전이 방향	최적 레이어	공유 피처 수	전이 AUC	타겟 Within	유지율
IC → MW	L40	535	0.916	0.966	94.8%
IC → SM	L16	154	0.894	0.981	91.1%
MW → SM	L36	656	0.882	0.981	89.9%
MW → IC	L38	1,085	0.833	0.964	86.4%
SM → IC	L40	459	0.820	0.964	85.1%
SM → MW	L16	160	0.812	0.966	84.1%
평균			0.859		88.6%

Table 4: 6개 방향별 교차 도메인 전이 AUC. '공유 피처 수'는 두 패러다임에서 모두 활성화율 ≥1%인 SAE 피처의 교집합 크기.

- **6개 쌍 모두 AUC 0.80 초과:** 범위 0.812-0.916, 평균 0.859. 패러다임 간 공유 신경 메커니즘의 강력한 증거.
- **IC가 소스로서 가장 우수:** IC→MW(0.916), IC→SM(0.894). IC의 BK 수(n=172)가 가장 많아 더 나은 학습 신호를 제공.
- **비대칭 전이:** IC→SM(0.894) > SM→IC(0.820). IC가 더 일반화 가능한 피처를 포착함을 암시.
- **평균 유지율 88.6%:** 한 패러다임에서 학습한 분류기가 다른 패러다임에서 within-domain AUC의 88.6%를 유지. 도박 위험의 신경 표현이 과제 프레이밍을 넘어 공유됨을 입증.

6. 한계점

1. **클래스 불균형:** SM(87/3200=2.7%), MW(54/3200=1.7%)의 적은 양성 사례로 F1 신뢰성 제한 및 fold간 분산 증가. MW는 fold당 BK ≈11건으로 소표본 불안정성이 높다.
2. **SM/MW 순열 검정 미실시:** IC에서만 $p<0.001$ 확인. SM/MW에서도 동일 수준의 통계적 유의성이 기대되나, 공식 검증이 필요하다.

3. **단일 모델:** 모든 결과가 Gemma-2-9B-IT에서 도출. LLaMA-3.1-8B 교차 모델 검증이 필요하다.

4. **Decision-point만 사용:** 현재 마지막 라운드 피처만 사용. Game-mean/max 집계(IC V2에서 AUC≈0.947-0.949)는 SM/MW에 미적용.

5. **전이 레이어 선택:** 최적 전이 레이어가 쌍마다 다름(L16-L40). 서로 다른 깊이에서 다른 피처가 일반화됨을 함의하나, 이 레이어 선택이 타겟 데이터에 의존(oracle selection)하므로 과적합 가능성이 있다.

6. **선형 분류기만 사용:** Logistic Regression이 비선형 패턴을 과소적합할 수 있으나, 높은 성능은 BK 신호가 대체로 선형 분리 가능함을 함의한다.

7. 논문에 대한 시사점

위 한계점을 감안하더라도, 본 분석 결과는 논문의 핵심 주장을 강화한다. 구체적인 반영 방안은 다음과 같다:

7.1 Section 3.2 (신경 메커니즘) 반영 사항

- **추가할 그림:** Figure 5(전이 행렬)를 Section 3.2에 삽입하여 교차 도메인 일반화를 시각적으로 제시.
- **수정할 주장:** 기존 단일 패러다임(IC) AUC 0.96 → '세 가지 독립 패러다임에서 AUC 0.96-0.98'로 확장.
- **추가할 근거:** R1 조기 예측(AUC 0.77-0.90)은 '프롬프트 처리 단계에서 위험 궤적이 결정됨'이라는 논문의 가설을 직접 지지.

7.2 Section 4 (토론) 반영 사항

- **SAE ≈ Hidden:** 동등한 예측 성능은 SAE 피처를 해석가능성 분석에 사용하는 것이 정보 손실 없이 정당화됨을 논의에 명시.
- **"도박 성향" 내부 상태:** 교차 도메인 전이(유지율 88.6%)는 창발적 미스정렬(emergent misalignment) 논의를 지지 — 과제별 패턴 매칭이 아닌 일반화 가능한 위험 추구 표현의 형성.
- **F1 보고:** SM/MW의 낮은 F1(0.27-0.53)은 낮은 기저율의 결과이며, AUC와 함께 보고하여 해석의 맥락을 제공해야 함.

8. 후속 분석 계획

아래 과제를 영향도(Impact)와 소요시간(Cost) 기준으로 정리하였다:

우선순위	과제	소요시간	영향도	설명
1	순열 검정 (SM/MW)	~30분	높음	통계적 유의성 공식 검증. 논문 필수.
2	핵심 피처 식별	~1시간	높음	LR 계수 상위 100개 SAE 피처 → GemmaScope 라벨 교차참조.
3	다층 앙상블	~2시간	중간	중간 레이어 결합으로 R1 조기예측 AUC 개선 가능성 검증.
4	활성화 패칭	~4시간(GPU)	높음	상위 피처의 인과적 역할 검증. 논문 Section 3.2 핵심.
5	PCA 궤적 시각화	~2시간	중간	BK vs 안전 게임의 라운드별 hidden state 궤적.
6	LLaMA 복제	~8시간(GPU)	중간	교차 모델 일반성 확인. 투고 시점에 따라 선택.

Table 5: 후속 분석 계획. 우선순위 1-2는 즉시 실행 가능(GPU 불필요).

부록: 실험 파라미터

파라미터	값
모델	Gemma-2-9B-IT (google/gemma-2-9b-it)
SAE	GemmaScope 131K (google/gemma-scope-9b-pt-res)
레이어	0-41 (42개)
Hidden 차원	3,584
SAE 피처 수	레이어당 131,072개
분류기	Logistic Regression (L2, C=1.0, balanced)
교차검증	5-fold 층화
피처 필터	활성화율 ≥ 1%
랜덤 시드	42
하드웨어	2x NVIDIA A100-SXM4-40GB
추출 시간	IC: 59분, SM: 220분, MW: 148분
분석 시간	~50분 (Goal A-C)