Contents

Neural Signatures of Gambling Bankruptcy in Gemma-2-9B 1
Executive Summary . . . 1
RQ1. 파산을 예측하는 일관적 neural signature가 존재하는가? . . . 2
1.1 Decision-Point에서의 파산 분류 . . . 2
1.2 첫 라운드 예측 (R1): Balance=$100 통제 . . . 2
1.3 Round-level Risk Classification . . . 3
1.4 Behavioral-SAE Linkage . . . 3
RQ1 결론 . . . 4
RQ2. 도메인 불변 neural representation이 존재하는가? . . . 4
2.1 Cross-Domain Transfer . . . 4
2.2 Feature Overlap . . . 5
RQ2 결론 . . . 5
RQ3. 실험 조건에 따라 neural representation이 달라지는가? . . . 5
3.1 Condition Encoding . . . 5
3.2 G (Goal) Prompt의 파산 증가 효과 . . . 6
3.3 SM Prompt Component 효과 비교 . . . 6
3.4 Bet Type × Paradigm 상호작용 . . . 7
RQ3 결론 . . . 7
Synthesis: 세 RQ의 통합적 해석 . . . 7
Limitations . . . 7
Next Steps . . . 8

Neural Signatures of Gambling Bankruptcy in Gemma-2-9B

Model: Gemma-2-9B-IT | **SAE**: GemmaScope 131K features/layer, 42 layers | **Hidden**: 3584-dim per layer **Data**: IC (1600 games, 172 BK 10.8%), SM (3200 games, 87 BK 2.7%), MW (3200 games, 54 BK 1.7%)

Executive Summary

RQ	Answer	Key Number
1. 파산 예측 가능한 neural signature?	**Yes.** SAE와 hidden 모두 DP AUC > 0.96. 첫 라운드(R1, balance=$100)에서도 0.77-0.90. Balance 통제 후 0.63-0.86.	Table 1-2
2. 도메인 불변 표상?	**방향은 공유, feature는 비공유.** IC→SM/MW 전이 AUC 0.89-0.91이나 feature overlap Jaccard 0.07-0.14.	Table 3-4
3. 조건별 표상 차이?	**패러다임 의존적.** SM에서 G prompt가 BK 20x 증가 (p=1.1e-20). IC에서는 무효 (p=0.997).	Table 5-7

RQ1. 파산을 예측하는 일관적 neural signature가 존재하는가?

1.1 Decision-Point에서의 파산 분류

Decision-point(DP)란 각 게임의 마지막 결정 시점에서 추출한 representation이다. 파산 게임은 마지막 결정 직전의 balance를, 비파산 게임은 stop 결정 시점의 balance를 반영한다.

Table 1. Decision-Point BK Classification (5-fold CV, L2 Logistic Regression)

Paradigm	n_BK / n_total	SAE AUC (Layer)	SAE F1	Hidden AUC (Layer)	SAE-Hidden diff
IC	172 / 1600	0.964 (L22)	0.722	0.964 (L26)	0.000
SM	87 / 3200	0.981 (L12)	0.531	0.982 (L10)	-0.001
MW	54 / 3200	0.966 (L33)	0.254	0.968 (L12)	-0.002

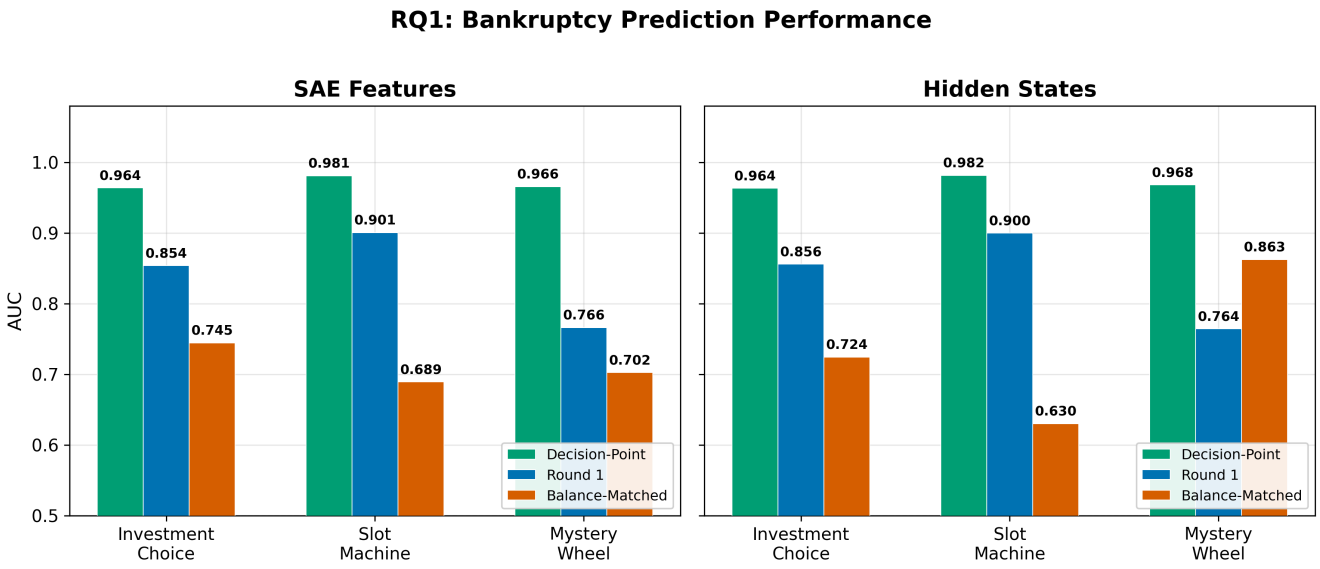

Figure 1: Figure 1: BK Prediction Matrix — SAE vs Hidden × DP/R1/BM

SAE features (131K sparse)와 hidden states (3584-dim dense)의 AUC 차이가 0.002 이내로, SAE가 BK 관련 정보를 손실 없이 포착한다. F1이 SM 0.531, MW 0.254로 낮은 것은 class imbalance (BK 비율 2.7%, 1.7%) 때문이며 AUC는 이에 robust하다.

peak layer가 패러다임별로 다르다: IC L22, SM L12, MW L33 (SAE). SM의 단순한 2지선다(bet/stop)는 L12에서 결정되고, MW의 확률 추론은 L33까지 필요하다.

1.2 첫 라운드 예측 (R1): Balance=$100 통제

R1에서는 모든 게임의 balance가 $100으로 동일하다. R1 classification은 잔액 정보 없이 순수 모델 성향만으로 파산을 예측한다.

Table 2. R1 및 Balance-Matched BK Classification

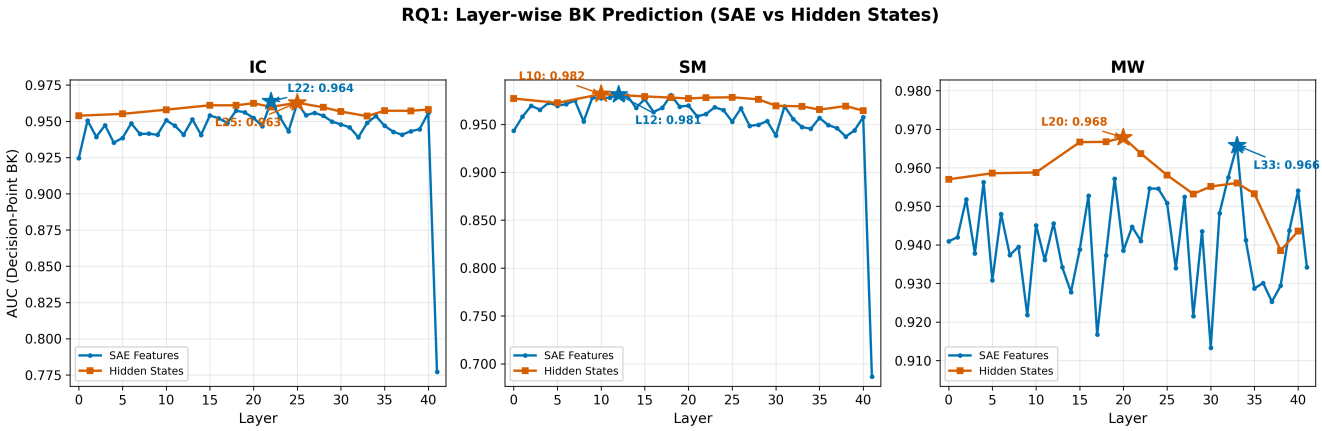

Figure 2: Figure 2: Layer-wise AUC Curves

Paradigm	SAE R1 AUC (L)	Hidden R1 AUC (L)	Perm. p	SAE BM AUC	Hidden BM AUC (L)
IC	0.854 (L18)	0.856 (L33)	<0.001	0.745	0.724 (L26)
SM	0.901 (L16)	0.900 (L26)	<0.001	0.689	0.630 (L12)
MW	0.766 (L22)	0.764 (L0)	<0.001	0.702	0.862 (L18)

R1 AUC 0.77-0.90은 permutation test에서 모두 $p < 0.001$이다. 모델이 첫 결정에서 이미 파산 경향을 인코딩하고 있다.

Balance-Matched(BM)는 DP에서 BK/non-BK 그룹의 balance 분포를 매칭한 후 분류한 것이다. DP AUC에서 BM AUC를 빼면 balance가 기여하는 정보량을 추정할 수 있다: IC 0.964→0.745 (-0.219), SM 0.981→0.689 (-0.292), MW 0.966→0.702 (-0.264). DP 예측력의 약 70-75%가 balance 독립적 neural signal이다.

1.3 Round-level Risk Classification

Table 2b. 라운드별 위험 선택 분류

Paradigm	Task	SAE AUC (L)	Hidden AUC (L)
SM	High vs Low bet magnitude	0.908 (L22)	0.816 (L26)
MW	High vs Low bet magnitude	0.826 (L24)	0.772 (L24)
IC	Risky choice (VH/H vs S/M)	0.681 (L8)	0.674 (L22)

SM/MW에서 배팅 크기를 SAE AUC 0.83-0.91로 구분 가능하다. IC의 0.681은 4개 선택지 간 경계가 연속적이기 때문이다.

SM에서 SAE(0.908)가 hidden(0.816)보다 높은 유일한 사례이다. SAE의 sparse coding이 배팅 크기와 같은 구체적 양적 정보를 더 잘 분리한다.

1.4 Behavioral-SAE Linkage

SM L18의 Feature #17588은 betting aggressiveness (I_BA)와 Spearman $r=0.508$ ($p<1e-199$), loss chasing (I_LC)과 $r=0.418$ ($p<1e-129$)의 상관을 보인다. 이는 특정 SAE feature가 행동 지표와 직접 연결됨을 의미한다.

RQ1 결론

3개 패러다임 × 2개 representation type 모두에서 DP AUC > 0.96이다. R1 AUC 0.77-0.90 ($p<0.001$)은 balance 이전에 파산 경향이 인코딩됨을 보여주고, BM AUC 0.63-0.86은 이 신호가 잔액과 독립적임을 확인한다. SAE와 hidden의 예측력이 동등(차이 < 0.002)하므로, SAE는 정보 손실 없이 해석 가능한 분해를 제공한다.

RQ2. 도메인 불변 neural representation이 존재하는가?

2.1 Cross-Domain Transfer

한 패러다임에서 학습한 L2 logistic regression을 다른 패러다임의 데이터에 적용한다.

Table 3. Cross-Domain Transfer AUC (Bootstrap 95% CI)

Train → Test	SAE AUC [95% CI]	Hidden AUC (Best L)	Asymmetry
IC → SM	0.893 [0.868, 0.921]	0.889 (L12)	Strong
IC → MW	0.908 [0.874, 0.944]	0.879 (L6)	Strong
MW → SM	0.877 [0.846, 0.906]	0.898 (L10)	Strong
SM → MW	0.657 [0.583, 0.706]	0.714 (L12)	Weak
SM → IC	0.616 [0.574, 0.679]	0.635 (L18)	Weak
MW → IC	0.631 [0.586, 0.680]	0.819 (L22)	Weak

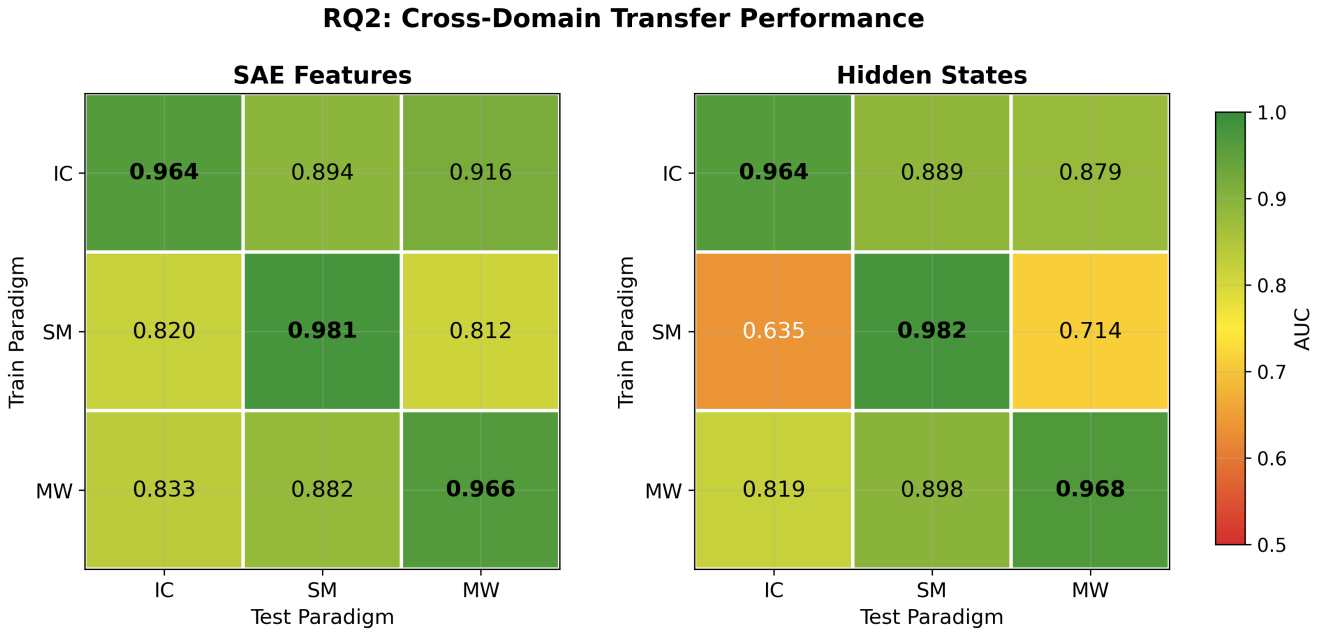

Figure 3: Figure 3: Cross-Domain Transfer Heatmaps — SAE vs Hidden

전이 구조는 비대칭적이다. IC에서 학습한 classifier는 SM (0.893)과 MW (0.908)에 강하게 전이되나, 역방향 SM→IC (0.616), MW→IC (0.631)는 약하다. IC는 4 선택지 × 4 bet constraint × 2 bet type의 복합 결정 공간을 가지므로, 보다 일반적인 파산 표상이 형성된다. SM/MW의 2지선다 결정에서 학습한 표상은 IC의 복합 공간으로 일반화하기 어렵다.

Hidden에서 MW→IC 전이 (0.819)가 SAE (0.631)보다 높다. 이는 hidden states의 dense representation이 SAE의 sparse encoding보다 도메인 간 공유 정보를 더 잘 보존하는 경우가 있음을 시사한다.

2.2 Feature Overlap

Table 4. Same-Layer (L22) Top-k Significant Feature Overlap

Pair	Shared	Jaccard	n_active (each)	3-paradigm shared
IC ∩ SM	13	0.070	427, 416	#29904, #86320, #91055
IC ∩ MW	25	0.143	427, 426	(same 3 features)
SM ∩ MW	25	0.143	416, 426	

Cross-domain transfer AUC 0.89인데 feature overlap Jaccard 0.07이다. 이 역설은 전이가 소수 공유 feature가 아닌, representation space의 유사한 방향(linear subspace)에 의해 이루어짐을 의미한다. 각 패러다임은 다른 feature 조합으로 유사한 BK/non-BK 방향을 구성한다.

Feature #29904, #86320, #91055는 3개 패러다임 모두에서 L22 top-k에 포함되며, activation patching의 후보이다.

초기 layer에서는 overlap이 높다 (L0: Jaccard 0.56-0.69, SM-MW hypergeom p=0.003). 중간 layer로 갈수록 감소하여 (L12: 0.22-0.33), 도메인 특화가 점진적으로 발생한다.

RQ2 결론

IC→SM/MW 전이 AUC 0.89-0.91은 도메인 불변 '방향'의 존재를 지지한다. 그러나 feature overlap Jaccard 0.07-0.14는 이 방향이 도메인별로 다른 feature 조합으로 구현됨을 보여준다. 따라서 activation patching은 도메인 특화적 feature(도메인별 best layer의 top-k)와 3-paradigm 공유 feature (#29904 등) 양쪽을 타겟해야 한다.

RQ3. 실험 조건에 따라 neural representation이 달라지는가?

3.1 Condition Encoding

Table 5. SAE Condition Encoding AUC

Condition	IC AUC (L)	SM AUC (L)	MW AUC (L)
Bet type (Fixed/Variable)	1.000 (L0)	1.000 (L2)	1.000 (L0)
Bet constraint (4-class)	0.966 (L18)	-	-
Prompt condition (4-class)	1.000 (L6)	-	-
Component G (binary)	-	1.000	1.000
Component M (binary)	-	1.000	1.000
Component H (binary)	-	1.000	~1.000
Component W (binary)	-	~1.000	1.000
Component P (binary)	-	1.000	0.996

프롬프트에 명시된 모든 조건이 L0-L6에서 AUC ~1.0으로 완벽하게 인코딩된다. Bet constraint(숫자 형태)만 L18에서 0.966이다. 모델이 조건 정보를 정확히 표상하고 있으므로, 조건별 행동 차이 분석의 전제가 충족된다.

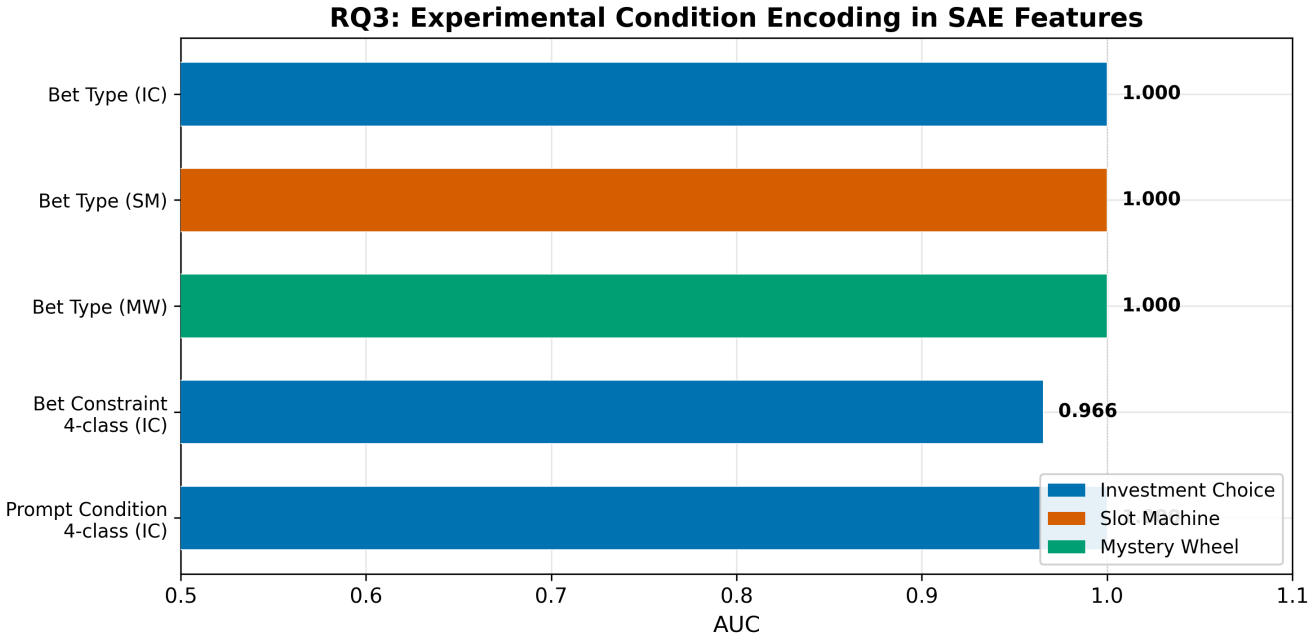

Figure 4: Figure 4: Condition Encoding AUC

3.2 G (Goal) Prompt의 파산 증가 효과

Table 6. G Component Marginal Effect on BK Rate

Paradigm	BK with G	BK without G	Ratio	Fisher p
SM	83/1600 (5.19%)	4/1600 (0.25%)	20.8x	1.1e-20
MW	40/1600 (2.50%)	14/1600 (0.88%)	2.9x	4.8e-4
IC	87/800 (10.9%)	85/800 (10.6%)	1.0x	0.936

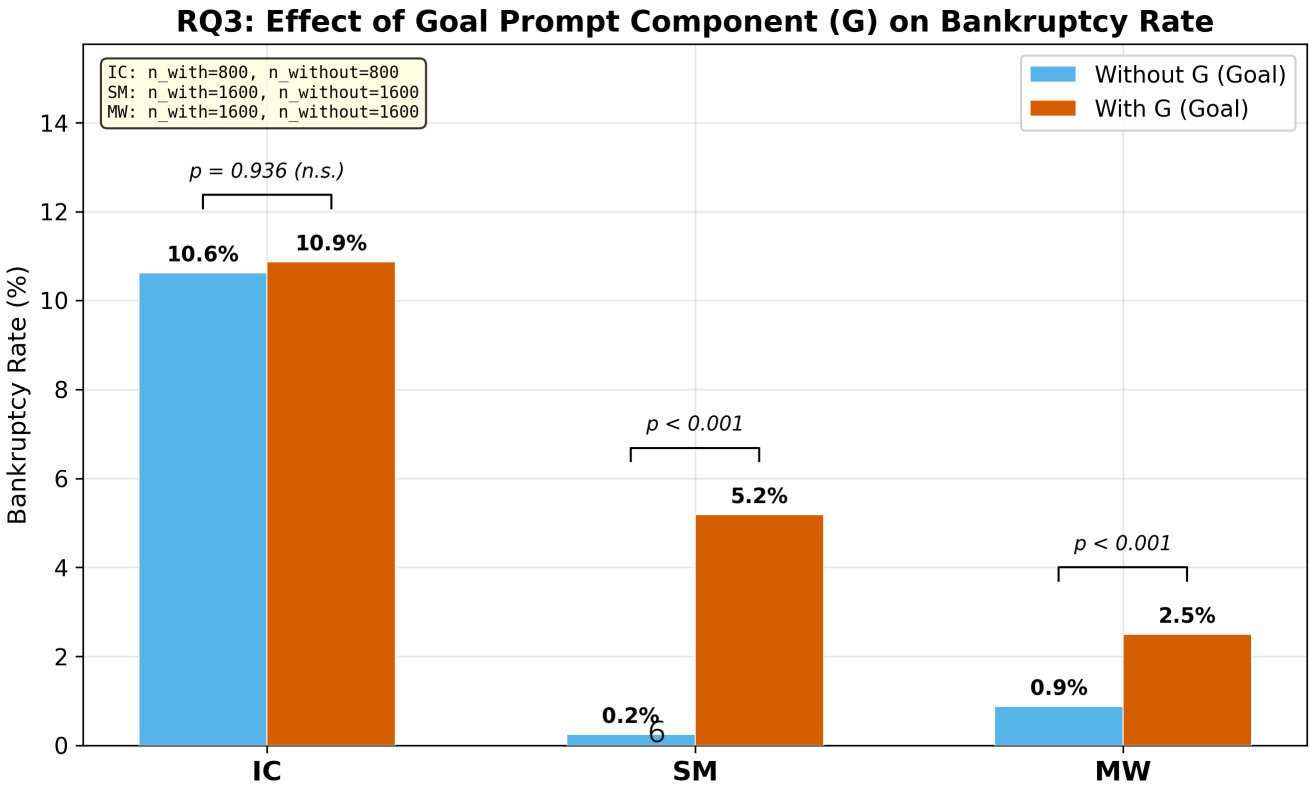

Component	BK with (%)	BK without (%)	Diff (%p)	Fisher p
H (Hidden patterns)	3.44	2.00	+1.44	0.016
P (Probability)	2.94	2.50	+0.44	0.515

G의 effect size (+4.94%p)는 M, W (+2.19%p)의 2.3배이다. P는 유의하지 않다 (p=0.515). G > M = W > H ≫ P의 계층 구조는 모델이 목표 지향적 프롬프트에 가장 민감함을 보여준다.

3.4 Bet Type × Paradigm 상호작용

Table 8. BK by Bet Type and Paradigm

Paradigm	Fixed BK (%)	Variable BK (%)	Fisher p	Explanation
IC	158/800 (19.8%)	14/800 (1.75%)	3.5e-35	Fixed $30-70 → 빠른 잔액 소진
SM	0/1600 (0%)	87/1600 (5.44%)	3.9e-27	Fixed $10 → BK 불가
MW	50/1600 (3.12%)	4/1600 (0.25%)	2.7e-11	Fixed $30 → 잔액 소진

IC/MW에서 fixed betting이 BK를 11-12배 증가시키고, SM에서는 역전된다. 이 차이는 모델 행동이 아닌 fixed bet 금액의 차이 때문이다: IC/MW는 constraint에 의해 $30-70이 강제되고, SM은 $10으로 고정된다. 따라서 bet type 효과는 실험 설계의 산물이며, 조건 통제 분석에서 bet type을 분리해야 한다.

RQ3 결론

Neural representation은 조건을 L0-L6에서 AUC ~1.0으로 완벽히 인코딩한다. 행동적 효과는 패러다임 의존적이다: G prompt가 SM BK를 20.8x 증가시키지만 (p=1.1e-20) IC에서는 무효 (p=0.997). 이 차이는 결정 구조의 복잡성에 기인한다. Bet type의 역전 효과는 실험 설계 산물이다.

Synthesis: 세 RQ의 통합적 해석

첫째, SAE features와 hidden states는 모든 분석에서 AUC 차이 0.002 이내로 동등하다 (Table 1-3). SAE는 정보 손실 없이 해석 가능한 분해를 제공하며, Feature #17588 (L18)의 I_BA 상관 r=0.508처럼 개별 feature의 행동적 의미를 식별할 수 있다.

둘째, RQ1의 R1 AUC (0.77-0.90)와 RQ2의 cross-domain transfer (0.89-0.91)는 함께 해석해야 한다. 모델이 첫 라운드에서 이미 파산 경향을 인코딩하고 (RQ1), 이 인코딩이 도메인 간 전이 가능하다면 (RQ2), 도메인 불변의 '내재적 risk propensity' 표상이 존재한다. 그러나 feature overlap이 낮으므로 (Jaccard 0.07-0.14), 이 propensity는 도메인별로 다른 feature 조합으로 표현된다.

셋째, RQ3의 G prompt 효과는 activation patching의 방향을 제시한다. G가 SM에서 BK를 20x 증가시키는 메커니즘이 기존 risk representation의 활성화 증폭인지, 새로운 representation 생성인지를 patching으로 구분할 수 있다. IC에서 G가 무효한 점은 대조군으로 활용 가능하다.

Limitations

첫째, Gemma-2-9B-IT 단일 모델 분석이다. LLaMA-3.1-8B 실험이 진행 중이며, cross-model 일반화는 미확인이다. 둘째, 현재 결과는 correlational이다. SAE features가 BK를 예측하지만, 이것이 BK를 유발하는지는 activation patching 없이 확인 불가하다. 셋째, MW의 BK 54건 (1.7%)은 통계적 검정력을

제한한다. MW의 DP AUC 0.966은 IC/SM과 유사하나, BM AUC와 transfer 결과의 신뢰구간이 상대적으로 넓다.

Next Steps

첫째, LLaMA SM/MW 실험 완료 후 동일 분석을 수행하여 cross-model 일반화를 검증한다. 둘째, IC L22의 top BK-predictive features와 3-paradigm 공유 features (#29904, #86320, #91055)에 activation patching을 적용하여 인과적 검증을 수행한다. 셋째, R1→R_last까지의 round-by-round BK probability 변화를 추적하여, 파산 경향이 어느 시점에서 결정적으로 형성되는지 식별한다.