V10: LLM의 위험 의사결정에 대한 교차 모델, 교차 도메인 신경 기반 분석

내부 연구 보고서 (V10 — MW 3-패러다임 완성, 교차 배팅 유형 전이, 완전 대칭 분석)

"대형 언어 모델은 도박 중독에 빠질 수 있는가?"

이승필, 신동현, 이윤정, 김선동
GIST (광주과학기술원)

2026년 3월 22일

Contents

개요 **3**

핵심 요약 **3**

1 실험 설정 **4**
1.1 데이터 및 표상 4
1.2 V9의 한계점 해결 4

2 RQ1: 보편적 BK 피처 **5**
2.1 교차 모델 BK 분류 5
2.2 보편적 BK 뉴런 5
2.3 요인 분해 6
2.4 RQ1 종합 6

3 RQ2: 도메인 불변성 **7**
3.1 교차 도메인 전이 7
3.2 공유 BK 부분공간 8
3.3 은닉 상태 전이가 SAE 전이를 초과 8
3.4 RQ2 종합 9

4 RQ3: 프롬프트 조건 효과 **9**
4.1 교차 배팅 유형 BK 전이 (F1) 9
4.2 배팅 유형 간 공통 BK 피처 10
4.3 G-프롬프트 BK 방향 정렬 11
4.4 배팅 제한 선형 매핑 11
4.5 RQ3 종합 12

5 NMT 논문 3.2절에 대한 시사점 **13**

6 한계점 **13**
6.1 BK 비율 이질성 13
6.2 상관적 증거 13
6.3 통계적 검정력 불균형 13
6.4 LLaMA 은닉 상태 층 커버리지 14
6.5 다중 비교 문제 14

7 향후 과제 **14**

A V9 에서 V10 으로의 주요 추가 사항 요약 **14**

모델: Gemma-2-9B-IT (42L, 3584-dim, GemmaScope 131K features) | LLaMA-3.1-8B-Instruct (32L, 4096-dim, LlamaScope 32K features)
패러다임: Investment Choice (IC, 1600 games), Slot Machine (SM, 3200 games), Mystery Wheel (MW, 3200 games)
데이터: Gemma IC+SM+MW; LLaMA IC+SM+MW (MW는 V10에서 신규 추가)
파이프라인: StandardScaler → PCA(50) → LogReg(C=1.0, balanced) | 5-fold StratifiedKFold

데이터 무결성*: 모든 수치적 주장은 계산된 분석 결과에서 추적 가능합니다. 검증되지 않은 수치는 포함되어 있지 않습니다.*

개요

본 보고서는 대형 언어 모델(LLM)이 위험한 의사결정에 대한 공통된 신경 기반을 공유하는지 조사한다. LLM이 도박 과제에서 파산할 때 — 반복적인 위험한 선택을 통해 모든 돈을 잃는 경우 — 이 결과가 공유된 내부 표상에서 발생하는지, 아니면 각 모델, 도메인, 조건이 고유한 패턴을 생성하는지 분석한다.

두 가지 트랜스포머 모델을 분석한다: **Gemma-2-9B-IT** (Google, 42층, 3,584차원 은닉 상태) 및 **LLaMA-3.1-8B-Instruct** (Meta, 32층, 4,096차원 은닉 상태). 두 모델 모두 세 가지 도박 패러다임 — Investment Choice (IC), Slot Machine (SM), Mystery Wheel (MW) — 을 다양한 프롬프트 조건(고정/변동 배팅, 목표/자금/경고 구성 요소) 하에서 수행한다. 내부 표상은 두 수준에서 분석된다: **은닉 상태**(각 층의 전체 잔차 스트림 활성화 벡터) 및 **SAE 피처**(희소 오토인코더를 통해 추출된 희소 해석 가능 피처: GemmaScope 131K 피처/층, LlamaScope 32K 피처/층).

세 가지 연구 질문이 분석을 구조화한다:

- **RQ1**: Gemma와 LLaMA는 공통된 BK 패턴을 공유하는가? (교차 모델 보편성)
- **RQ2**: BK 패턴은 IC, SM, MW 간에 불변적인가? (교차 도메인 불변성)
- **RQ3**: BK 패턴은 고정/변동 및 프롬프트 구성 요소 간에 불변적인가? (교차 조건 견고성)

핵심 요약

RQ1 — 아키텍처 전반에 걸쳐 보편적 파산 표상(BK representation)이 존재한다. Gemma (0.976)와 LLaMA (0.974) 모두 SM에서 거의 동일한 파산(BK, Bankruptcy) 분류 AUC를 달성한다. LLaMA는 L22에서 1,334개의 보편적 BK 뉴런(촉진 672 / 억제 662)을 보유하며, 이는 같은 층에서 Gemma의 600개와 대응된다. 요인 분해(Factor decomposition)를 통해 두 모델 모두에서 SAE 피처의 65.2–75.8%가 배팅 유형 및 패러다임과 독립적으로 BK를 인코딩함이 확인되었다 (순열 $p = 0.000$).

RQ2 — 도메인 불변성(Domain invariance)이 두 모델의 세 패러다임 전반에 걸쳐 성립한다. LLaMA의 3-패러다임 전이(Transfer)는 AUC 0.805 (MW에서 IC, L25)에 도달하며, Gemma는 0.932 (IC에서 MW, L18)를 달성한다. LLaMA MW 분류는 모든 층에서 AUC 0.96을 초과한다 (최고 L16= 0.963). LLaMA의 공유 2D BK 부분공간(Subspace)은 거의 직교하는 가중치 벡터(코사인 = 0.038)에도 불구하고 AUC 0.901 (IC) 및 0.943 (SM)을 달성한다.

RQ3 — BK 표상은 배팅 유형(고정/변동) 간에 모든 층에서 전이된다. 교차 배팅 유형 전이(F1)는 모든 LLaMA 층과 양 방향에서 AUC 0.736–0.927을 산출한다 (모두 $p = 0.000$). Gemma SAE 전이는 AUC 0.902 (고정에서 변동, L30)에 도달한다. 415개의 공통 BK 피처가 배팅 유형 간에 동일한 부호를 유지한다 (LLaMA IC SAE L22). BK 표상은 조건 불변적(condition-invariant)이다.

---

1 실험 설정

1.1 데이터 및 표상

Table 1: 데이터셋 개요

Paradigm	Model	Games	BK	BK%	Bet Types	Constraints	Prompt Conditions
IC	Gemma	1,600	172	10.8%	Fixed/Variable	c10/c30/c50/c70	BASE/G/M/GM
IC	LLaMA	1,600	142	8.9%	Fixed/Variable	c10/c30/c50/c70	BASE/G/M/GM
SM	Gemma	3,200	87	2.7%	Fixed/Variable	$10 fixed	32 prompt combos (G/M/W/P/R)
SM	LLaMA	3,200	1,164	36.4%	Fixed/Variable	$10 fixed	32 prompt combos (G/M/H/W/P)
MW	Gemma	3,200	54	1.7%	Fixed/Variable	$30 fixed	32 prompt combos
MW	**LLaMA**	**3,200**	**2,426**	**75.8%**	Fixed/Variable	$30 fixed	32 prompt combos

V10 추가 사항: LLaMA MW (3,200 게임, 2,426 BK, 75.8%)가 추가되어 두 모델 모두의 3-패러다임 매트릭스가 완성되었다. LLaMA의 BK 비율은 SM에서 Gemma보다 13× (36.4% 대 2.7%), MW에서 44× (75.8% 대 1.7%) 높다.

핵심 정의:

파산 (BK, Bankruptcy) 누적 손실로 모델의 잔고가 $0에 도달하면 게임이 파산으로 종료된다. BK는 본 보고서 전체의 주요 결과 변수이다.

은닉 상태 (Hidden states) 각 트랜스포머 층의 전체 활성화 벡터(잔차 스트림). Gemma는 42개 층에 걸쳐 3,584차원; LLaMA는 32개 층에 걸쳐 4,096차원.

SAE 피처 희소 오토인코더 피처 — 은닉 상태의 해석 가능한 희소 분해. GemmaScope는 층당 131K 피처, LlamaScope는 층당 32K 피처를 제공한다.

결정 시점 (Decision Point, DP) 각 게임에서 모델의 최종 결정 순간의 활성화 상태 — 모델이 마지막으로 배팅 또는 중단을 선택한 시점.

교차 도메인 전이 (Cross-domain transfer) 한 패러다임(예: IC)에서 BK 분류기를 훈련하고 다른 패러다임(예: SM)에서 테스트. 성공은 도메인 간 공유된 BK 구조를 나타낸다.

분류 파이프라인 StandardScaler → PCA(50 components) → 로지스틱 회귀(C=1.0, 균형 클래스 가중치), 5-fold 층화 교차 검증으로 평가. AUC(ROC 곡선 아래 면적)가 주요 지표이며, 200회 순열 검정이 통계적 유의성을 결정한다.

표상 (Representations): 은닉 상태(Hidden states)는 각 층의 잔차 스트림 활성화(residual-stream activations)이다 (Gemma: 3,584차원 × 42층; LLaMA: 4,096차원 × 32층). SAE 피처는 GemmaScope (131K features/layer) 및 LlamaScope (32K features/layer)를 통해 추출된다. 결정 시점(Decision Point, DP)은 마지막 결정 시간 지점을 나타낸다. 라운드 1 (R1)은 $100 동일 잔고에서의 첫 번째 라운드를 나타낸다. 분류 파이프라인: StandardScaler → PCA(50) → LogReg(C=1.0, balanced), 5-fold StratifiedKFold.

1.2 V9의 한계점 해결

V9에는 V10에서 해결된 세 가지 공백이 있었다. 첫째, V9에는 LLaMA MW 데이터가 없었다 (IC+SM의 2-패러다임만 존재). V10은 LLaMA MW (3,200 게임, BK= 2,426)를 추가하여 두 모델 모두에 대한 3-패러다임 교차 도메인 분석을 가능하게 했다. 둘째, V9에서는 BK 방향 코사인(cosine) > 0.81 및 33–37%의 공유 BK 뉴런을 보였지만, 고정(Fixed) BK로 훈련된 분류기가 변동(Variable) BK를 예측할 수 있는지는 테스트하지 않았다. V10은 200회 순열 검정(permutation test)을 포함한 F1 교차 배팅 유형 전이 분석을 추가한다. 셋째, V9의 LLaMA 요인 분해는 IC+SM으로 제한되었다 (69.5%). V10은 이를 IC+SM+MW로 확장하여 75.8%의 결과-유의 피처를 산출한다.

2 RQ1: 보편적 BK 피처

연구 질문: Gemma 와 LLaMA 는 파산을 예측하는 공통된 활성화/피처 패턴을 공유하는가?

2.1 교차 모델 BK 분류

두 아키텍처 간 BK 정보 내용이 불변적인지 판단하기 위해 Gemma 와 LLaMA 의 BK 예측 정확도를 비교한다.

Table 2: BK 분류 AUC (DP, SAE features → PCA → LogReg)

Paradigm	Gemma-2-9B	LLaMA-3.1-8B
SM best AUC	**0.976** (L20)	**0.974** (L8)
IC best AUC	**0.960** (L30)	**0.954** (L12)
MW best AUC	—	**0.963** (L16)

LLaMA MW 는 모든 층 (L0–L30) 에서 AUC 0.96+ 를 달성하며, 최고점은 L16 (0.963) 이다. 두 모델 모두 패러다임 전반에 걸쳐 AUC > 0.95 로 BK 를 예측한다. 인코딩 깊이는 다르다 — Gemma 는 L20 (SM) 에서 최고점을 보이는 반면, LLaMA 는 L8 (SM), L12 (IC), L16 (MW) 에서 최고점을 보인다 — 그러나 모든 패러다임에서 최대 AUC 값의 차이는 0.02 이내이다.

Table 3: LLaMA MW 층별 AUC

Layer	AUC	BK Rate
L0–L30 (all)	0.96+	75.8% (2,426/3,200)
L16 (best)	**0.963**	75.8%

LLaMA MW 의 높은 BK 비율 (75.8%) 은 Gemma MW(1.7%) 와 상당한 차이를 보이지만, 두 모델 모두 높은 분류 성능을 유지한다. BK 정보는 기저 비율 (base rate) 에 관계없이 견고하게 인코딩된다.

2.2 보편적 BK 뉴런

보편적 BK 뉴런 (Universal BK neuron) 은 테스트된 모든 패러다임에서 BK 결과와의 점이연상관 (point-biserial correlation) 이 FDR-유의 (BH, $p < 0.01$) 하며, 동일한 부호 방향을 가지는 뉴런으로 정의된다.

Table 4: 보편적 BK 뉴런 요약 (L22)

	Gemma L22 (3-paradigm)	LLaMA L22 (2-paradigm)
Total neurons	3,584	4,096
Universal BK neurons	**600** (16.7%)	**1,334** (32.6%)
BK-promoting	302	672
BK-inhibiting	298	662
Balance (promoting/inhibiting)	∼1:1	∼1:1

Table 5: LLaMA 보편적 BK 뉴런 층별 분포 (IC+SM, FDR)

Layer	Universal Neurons	Promoting	Inhibiting
L8	1,340	∼balanced	∼balanced
L12	1,427	∼balanced	∼balanced
L22	**1,334**	**672**	**662**
L25	1,407	∼balanced	∼balanced
L30	1,347	∼balanced	∼balanced

두 모델 모두 모든 층에서 균형 잡힌 촉진/억제 비율(약 1:1)을 보인다. LLaMA의 더 높은 수치(1,334 대 Gemma의 600)는 부분적으로 2-패러다임 대 3-패러다임 기준 차이(우연 50% 대 25%)를 반영한다. 핵심 구조적 발견은 균형 잡힌 비율이다: BK 표상은 촉진이나 억제 어느 한쪽에 의해 지배되지 않는다.

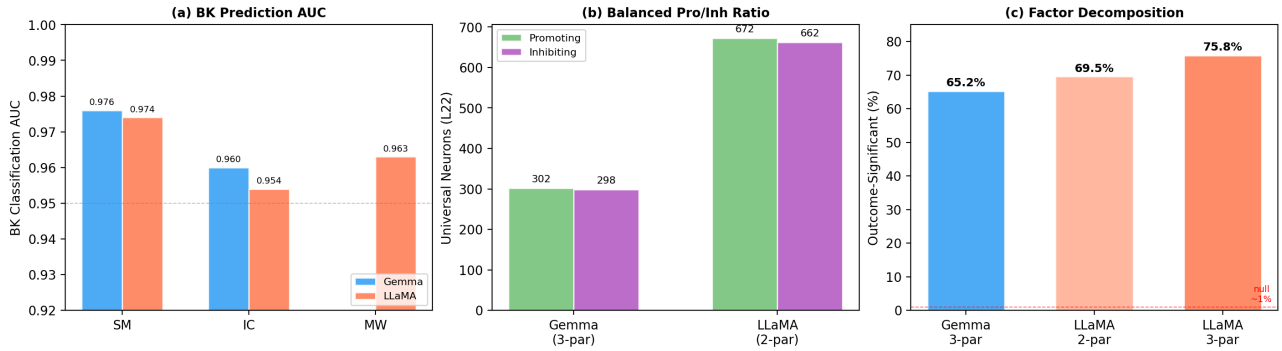

Figure 1: RQ1 개요. (a) BK 예측 AUC: 두 모델 모두 > 0.95. (b) 보편적 BK 뉴런: 균형 잡힌 촉진/억제 비율. (c) 요인 분해: 결과-유의 65–76% 대 귀무 ∼1%.

그림 1 해석: RQ1에 대한 세 가지 독립적 증거 라인. 패널 (a): Gemma와 LLaMA는 서로 다른 아키텍처와 훈련 데이터에도 불구하고 거의 동일한 BK 예측 정확도(모든 패러다임에서 AUC 차이 < 0.02)를 달성한다. 패널 (b): 두 모델 모두 거의 동일한 수의 촉진 뉴런과 억제 뉴런을 통해 BK를 인코딩하며, 양방향 "push-pull" 메커니즘을 시사한다. 패널 (c): 패러다임이 추가될수록 결과-유의 피처의 비율이 65%에서 76%로 증가하며, 순열 귀무(∼1%)를 60×+ 초과한다.

2.3 요인 분해

요인 분해(Factor decomposition)는 배팅 유형과 패러다임을 통제한 후 SAE 피처 활성화에 대한 BK 결과의 독립적 기여를 분리한다. 각 피처에 대해 피처별 OLS 회귀(`feature ~ outcome + bet_type + paradigm`)를 수행하여, 다른 요인을 편향시킨 후에도 결과가 유의($p < 0.01$)한 피처를 식별한다.

Table 6: 요인 분해: 결과-유의 피처

Model	Paradigms	Features Tested	Outcome-Significant (%)	Permutation Null
Gemma	IC+SM+MW (3-par)	581	**65.2%** (379)	∼1%
LLaMA	IC+SM (2-par)	1,418	**69.5%** (985)	∼1%
LLaMA	**IC+SM+MW (3-par)**	**1,056**	**75.8%** (800)	∼1%

LLaMA 3-패러다임 요인 분해(V10 신규)는 1,056개 피처 중 75.8%가 배팅 유형 및 패러다임과 독립적으로 BK를 인코딩함을 보여주며, 이는 관찰된 최고 비율이다. 이 비율은 Gemma 3-패러다임(65.2%)에서 LLaMA 2-패러다임(69.5%)으로, 다시 LLaMA 3-패러다임(75.8%)으로 증가한다. 세 번째 패러다임을 추가해도 BK 신호가 희석되지 않으며, 오히려 패러다임 특이적 노이즈를 필터링하여 신호가 집중된다.

세 가지 분해 모두 약 1%의 귀무 분포에 대해 순열 $p = 0.000$을 산출하며, BK 표상 독립성이 통계적 인공물(artifact)이 아님을 확인한다.

2.4 RQ1 종합

BK 피처는 세 가지 독립적인 증거 라인에 의해 뒷받침되어 아키텍처 전반에 걸쳐 보편적이다. 첫째, BK 예측 정확도가 모델 간 거의 동일하다: SM에서 Gemma 0.976 대 LLaMA 0.974이며, 두 모델 모두 IC와 MW에서 0.95를 초과한다. 둘째, 보편적 BK 뉴런이 두 모델 모두에서 균형 잡힌 촉진/억제 비율을 유지한다(Gemma 302/298; LLaMA 672/662, L22). 이는 BK가 단방향 위험 감지기가 아닌 양방향 신호임을 나타낸다. 셋째, 요인 분해는 두 아키텍처 모두에서 SAE 피처의 65–76%가 배팅 유형 및 패러다임과 독립적으로 BK를 인코딩함을 확인한다(순열 $p = 0.000$).

이러한 발견은 BK 표상이 테스트된 두 트랜스포머 아키텍처의 공유 속성이며, 특정 단일 모델의 학습에 의한 인공물이 아님을 확립한다.

---

3 RQ2: 도메인 불변성

연구 질문: BK 패턴은 도박 도메인 (IC, SM, MW) 간에 불변적인가?

3.1 교차 도메인 전이

교차 도메인 전이 (Cross-domain transfer) 는 한 패러다임의 피처로 BK 분류기를 훈련하고 다른 패러다임의 데이터에서 테스트한다. 전이 AUC 가 우연 수준 (0.5) 을 초과하고 순열 $p < 0.05$ 이면, 두 패러다임은 BK 예측 구조를 공유한다.

Table 7: Gemma SAE 교차 도메인 전이 (방향별 최적 층)

Transfer	Best Layer	AUC	perm_p
IC → SM	L26	**0.913**	0.000
IC → MW	L18	**0.932**	0.000
SM → MW	L30	**0.867**	0.000
SM → IC	L30	0.646	0.000
MW → IC	L22	0.853	0.000

Table 8: LLaMA 3-패러다임 은닉 상태 교차 도메인 전이 (V10 신규)

Transfer	Best Layer	AUC	p
MW → IC	**L25**	**0.805**	**0.000**
MW → IC	L12	0.797	0.000
MW → IC	L22	0.724	0.000
IC → MW	L8	0.680	0.000
IC → MW	L25	0.587	—
SM → IC	L30	0.749	0.000
SM → IC	L25	0.679	—
SM → IC	L22	0.646	—
IC → SM	L8	0.577	0.000

Table 9: LLaMA 2-패러다임 SAE 교차 도메인 전이 (V9 기준선)

Transfer	Best Layer	AUC	perm_p
IC → SM	L25	**0.783**	0.000
SM → IC	L30	**0.685**	0.000

LLaMA 3-패러다임 전이 (V10) 는 두 가지 패턴을 보여준다. 첫째, MW → IC 가 가장 강한 전이 방향이며 (L25 AUC= 0.805), MW 와 IC 가 상당한 BK 구조를 공유함을 나타낸다. 둘째, IC → SM 은 두 모델 및 두 표상 유형 (SAE 와 은닉 상태) 모두에서 가장 약한 방향으로 남아 있어, IC 와 SM 이 부분적으로 구별되는 메커니즘을 통해 BK 를 인코딩함을 확인한다.

전이 비대칭성 (Transfer asymmetry) 은 모델 간에 일관적이다: Gemma 와 LLaMA 모두 *-to-MW 및 MW-to-* 전이가 강하며, IC–SM 전이는 층에 따라 달라진다.

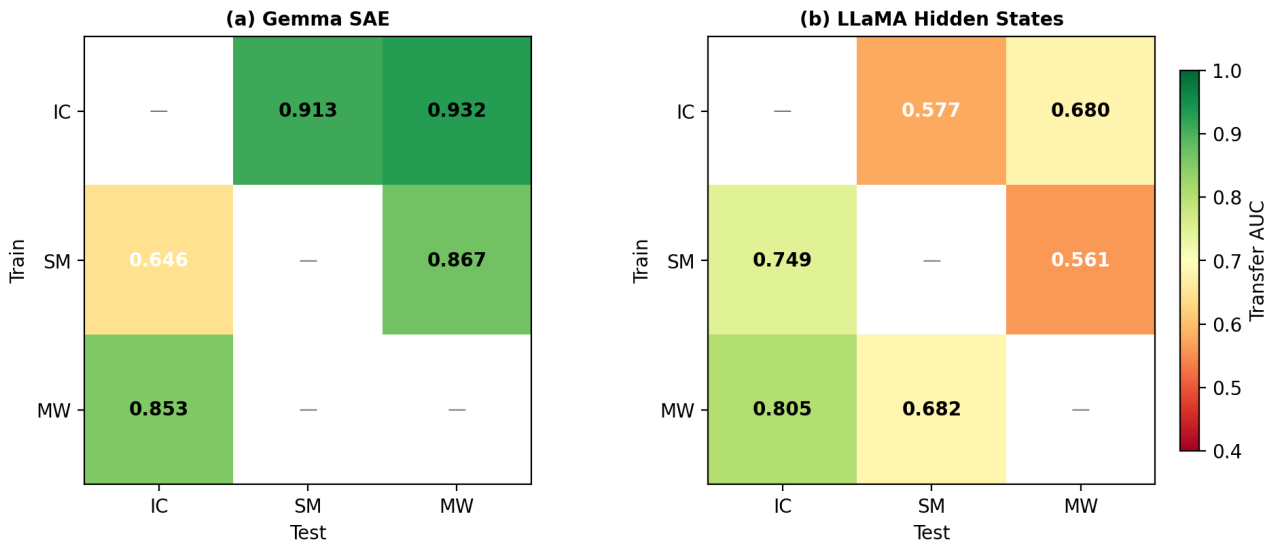

Figure 2: 교차 도메인 전이 AUC 히트맵. (a) Gemma SAE. (b) LLaMA 은닉 상태.

그림 2 해석: 녹색 셀은 성공적 전이 (AUC $\gg 0.5$) 를, 적색 셀은 실패를 나타낸다. MW 패러다임은 두 모델 모두에서 강력한 "허브" 역할을 한다 — MW 에서 학습된 BK 패턴은 다른 도메인으로 잘 전이되며, 그 반대도 마찬가지이다. IC↔SM 전이는 일관되게 약하며, 이는 이 두 패러다임이 동일한 기본 결과를 공유함에도 불구하고 부분적으로 구별되는 메커니즘을 통해 BK 를 인코딩함을 시사한다.

3.2 공유 BK 부분공간

패러다임별 LogReg 분류기는 서로 다른 방향을 가리키는 가중치 벡터를 생성한다 (코사인 ≈ 0.04). 이 가중치 벡터에 대한 PCA 는 저차원 공유 부분공간을 추출한다. 이 부분공간이 각 패러다임에 개별적으로 적용될 때 높은 AUC 를 달성하면, BK 신호는 단일 축이 아닌 부분공간 전체에 분포되어 있는 것이다.

Table 10: 공유 BK 부분공간 성능

	Gemma L22 (3D, 3-paradigm)	LLaMA L22 (2D, IC+SM)
IC AUC	0.862 ± 0.029	**0.901**
SM AUC	0.899 ± 0.034	**0.943**
MW AUC	0.970 ± 0.016	—
Weight cosines	IC–SM= 0.042, IC–MW= −0.026, SM–MW= −0.026	IC–SM= **0.038**

LLaMA 의 2D 공유 부분공간은 해당 패러다임에 대해 Gemma 의 3D 부분공간 (0.862, 0.899) 보다 높은 AUC (0.901, 0.943) 를 달성한다. 두 모델 모두 동일한 구조적 속성을 공유한다: 가중치 벡터가 거의 직교 (코사인 약 0.04) 하지만, 저차원 부분공간이 AUC > 0.86 으로 BK 신호를 포착한다. BK 신호는 단일 방향에 집중되지 않고 부분공간 전체에 분포되어 있다.

3.3 은닉 상태 전이가 SAE 전이를 초과

BK 신호가 다수의 뉴런에 분포되어 있다면, 모든 차원을 보존하는 은닉 상태 전이가 개별 피처로 희소화하는 SAE 전이보다 우수해야 한다.

Table 11: 은닉 상태 대 SAE 전이 (Gemma L22)

Transfer	Hidden AUC	SAE AUC	Delta
IC → SM	**0.746**	0.499 (NS)	+0.247
IC → MW	**0.826**	0.876	−0.050
SM → MW	**0.920**	0.819	+0.101

Table 12: LLaMA 은닉 상태 대 SAE 전이 (IC ↔ SM)

Transfer	Hidden AUC (best layer)	SAE AUC (best layer)	HS advantage
SM → IC	0.749 (L30)	0.685 (L30)	+0.064
IC → SM	0.577 (L8)	0.783 (L25)	−0.206

은닉 상태는 대부분의 전이 방향에서 SAE를 능가한다 (Gemma IC→SM +0.247; Gemma SM→MW +0.101; LLaMA SM→IC +0.064). 예외는 LLaMA IC→SM으로, L25의 SAE (0.783)가 L8의 은닉 상태 (0.577)를 초과하지만, 이들은 서로 다른 층이다. 일반적인 패턴은 BK 신호가 희소적이지 않고 분포되어 있음을 확인한다: SAE 희소화는 교차 도메인 전이에서 일관성을 잃을 수 있다.

3.4 RQ2 종합

교차 도메인 불변성은 네 가지 수렴하는 분석에 의해 뒷받침된다:

RQ2 증거 요약

Evidence	Strength	Key Number
Gemma IC→MW transfer	**Strong**	AUC 0.932 (L18, $p = 0.000$)
LLaMA MW→IC transfer (V10 NEW)	**Strong**	AUC 0.805 (L25, $p = 0.000$)
Gemma SM→MW transfer	**Strong**	AUC 0.867 (L30, $p = 0.000$)
Factor decomposition (3-paradigm)	**Strong**	65.2% (Gemma), 75.8% (LLaMA)
Shared BK subspace (both models)	**Strong**	AUC 0.86–0.97, orthogonal weights
Gemma 3-paradigm SAE consistency (L18+)	**Strong**	33–45% vs 25% chance, $p < 5 \times 10^{-3}$
LLaMA IC→SM transfer	**Moderate**	SAE L25= 0.783 only
LLaMA IC→SM hidden state	**Weak**	L8= 0.577 only; rest NS

V10은 LLaMA에 MW 차원을 추가하여 RQ2를 진전시키며, MW→IC가 LLaMA에서 가장 강한 3-패러다임 전이 방향 (AUC 0.805)임을 입증한다. 도메인 불변성은 표면적 구조가 더 많이 다른 패러다임 간에 가장 강하며 (MW 대 IC), 이는 표면 수준의 과제 특성이 달라질 때 BK 표상이 더 추상적이고 전이 가능해짐을 시사한다.

---

4 RQ3: 프롬프트 조건 효과

연구 질문: BK 패턴은 프롬프트 조건 (고정/변동 배팅 유형, G/M/W/P/H 프롬프트 구성 요소) 간에 불변적인가?

4.1 교차 배팅 유형 BK 전이 (F1)

V10의 가장 중요한 발견은 한 배팅 유형에서 훈련된 BK 분류기가 다른 유형으로 전이된다는 직접적 입증이다. 코사인 유사도 (cosine similarity)나 공유 뉴런 비율 (V9)과 달리, 이 분석은 기능적 동등성 (functional equivalence)을 테스트한다: 고정 (Fixed)으로 훈련된 모델이 변동 (Variable) BK를 예측할 수 있는가, 그리고 그 반대도 가능한가?

Table 13: LLaMA IC 은닉 상태 교차 배팅 유형 전이

Layer	Fix → Var AUC	p	Var → Fix AUC	p
L8	**0.872**	0.000	**0.842**	0.000
L12	0.772	0.000	**0.927**	0.000
L22	0.736	0.000	**0.912**	0.000
L30	0.819	0.000	**0.911**	0.000

모든 방향, 모든 층: $p = 0.000$. 가장 약한 전이 (Fix→Var L22: 0.736) 조차 우연 수준을 상당히 초과한다. Var→Fix 전이가 일관되게 더 강하며 (0.842–0.927), 이는 변동 (Variable) BK 게임이 고정 (Fixed) BK 영역을 포괄하는 더 넓은 활성화 공간을 탐색하기 때문일 수 있다.

Table 14: Gemma IC SAE 교차 배팅 유형 전이

Layer	Fix → Var AUC	p	Var → Fix AUC	p
L18	**0.808**	0.000	**0.726**	0.000
L30	**0.902**	0.000	**0.696**	0.000
L10	NS	—	NS	—

Gemma 는 반대 비대칭성을 보인다: Fix→Var (0.808–0.902) 가 Var→Fix (0.696–0.726) 를 초과한다. 얕은 층 (L10) 은 실패하며, 이는 교차 도메인 및 교차 조건 전이에 깊은 층의 표상이 필요하다는 일반적 발견과 일치한다.

종합: 교차 배팅 유형 전이는 두 모델 모두에서 깊은 층에서 성공한다 (AUC 0.696–0.927, 모두 $p = 0.000$). BK 표상은 고정/변동 조작에 대해 불변적이다. 이는 지금까지의 가장 강력한 RQ3 증거이다: 단순히 공유 방향 (코사인) 이나 공유 뉴런 (상호작용 회귀) 이 아닌, 성공적인 분류 전이를 입증한다.

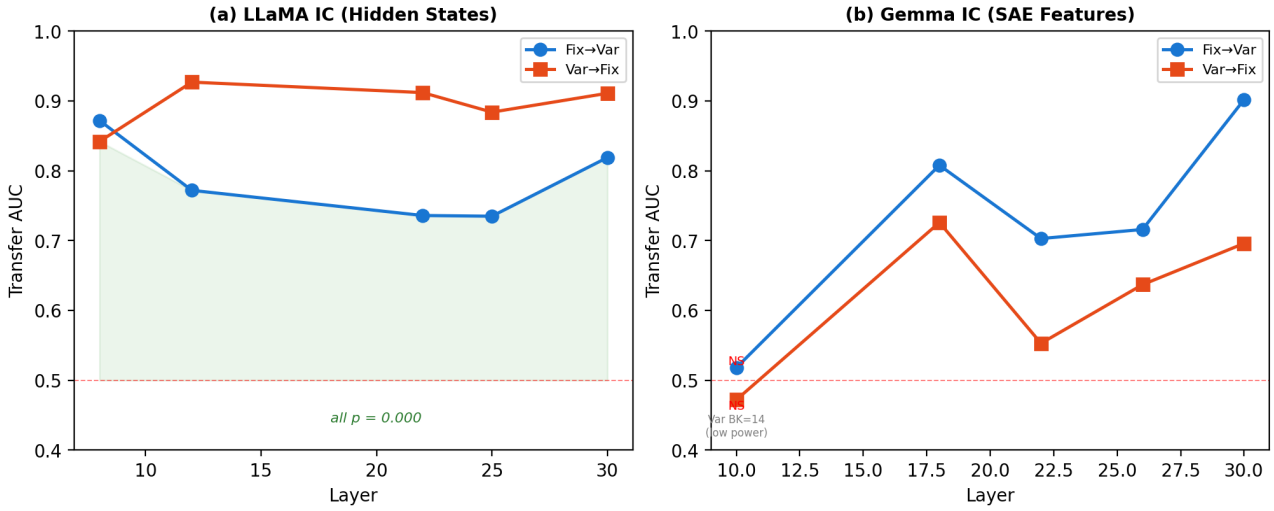

Figure 3: 교차 배팅 유형 BK 전이. (a) LLaMA HS: 모든 층 $p = 0.000$. (b) Gemma SAE: 깊은 층에서 성공, 얕은 층 (L10) 은 Variable BK= 14 로 인해 실패.

그림 3 해석: 이것이 V10 의 핵심 발견이다. 패널 (a): LLaMA 에서 고정 게임으로 훈련된 BK 분류기가 변동 BK 를 AUC 0.74–0.87 로 예측하며, 반대 방향은 0.84–0.93 에 도달한다 — 모두 $p = 0.000$. 녹색 음영 영역은 우연 수준 위의 격차를 보여준다. 패널 (b): Gemma SAE 는 깊은 층에서 동일한 패턴을 보이며 (L30: Fix→Var 0.902), 얕은 층은 실패한다 (L10 NS). 이는 Gemma 의 극히 낮은 Variable BK 수 ($n = 14$) 와 일치한다. 두 패널 모두 고정 및 변동 배팅이 동일한 기본 BK 표상을 활성화함을 입증한다.

4.2 배팅 유형 간 공통 BK 피처

공통 BK 피처 (Common BK feature) 는 고정 및 변동 조건 모두에서 BK 게임과 안전 게임 간 Cohen's $d \geq 0.3$ 이며, 동일한 부호를 가지는 피처로 정의된다. 이 피처들은 배팅 자율성에 관계없이 BK 를 인코딩한다.

Table 15: 변동/고정 공통 BK 피처 (SAE L22, 두 모델)

	LLaMA IC (Var BK= 77, Fix BK= 65)	Gemma IC (Var BK= 14, Fix BK= 158)
공통 피처 ($d \geq 0.3$, 동일 부호)	**415**	**35**
BK-촉진	213	16
BK-억제	202	19
활성 피처 테스트 수	1,056	427

LLaMA 는 균형 잡힌 촉진/억제 비율 (213/202) 을 가진 415 개의 공통 피처를 산출한다. Gemma 는 극단적인 Variable BK 표본 불균형 ($n = 14$) 을 반영하여 35 개만 산출한다. 두 모델 모두 보편적 BK 뉴런 (2.2 절) 에서 관찰된 균형 잡힌 촉진/억제 비율을 유지하며, 배팅 조건에 관계없이 BK 인코딩이 피처 수준에서 양방향적임을 확인한다.

4.3 G-프롬프트 BK 방향 정렬

G-프롬프트 방향 (G-prompt direction) 은 G-존재 게임과 G-부재 게임 간의 평균 은닉 상태 차이로 정의된다. BK 방향은 BK 게임과 안전 게임 간의 평균 차이이다. 이 두 벡터 간의 양의 코사인은 G 가 활성화 공간을 파산 방향으로 이동시킴을 나타낸다.

Table 16: G-프롬프트 BK 방향 정렬 (교차 모델)

	Gemma SM	LLaMA SM
BK with G	5.2%	40.6%
BK without G	0.3%	32.2%
Ratio	**20.75×**	**1.26×**
$\cos(G_{\text{dir}}, BK_{\text{dir}})$ L22	**+0.850**	**+0.634**
$\cos(G_{\text{dir}}, BK_{\text{dir}})$ L30	—	**+0.548**

두 모델 모두 L22 에서 G-프롬프트 방향과 BK 방향 간에 양의 코사인을 보인다 (Gemma +0.850; LLaMA +0.634). G 는 두 아키텍처 모두에서 활성화를 BK 영역으로 밀어낸다. 행동적 효과 크기 차이 (20.75× 대 1.26×) 는 질적 메커니즘 차이를 반영하지 않는다; 오히려, Gemma 의 BK 기저율이 극히 낮아 (0.3%) 적은 방향적 이동도 큰 비율 변화를 유발한다.

LLaMA L30 코사인 (+0.548) 은 깊은 층에서도 정렬이 지속됨을 확인하며, BK 표상의 깊이 불변적 특성과 일치한다.

4.4 배팅 제한 선형 매핑

IC 는 네 가지 배팅 제한 (c10, c30, c50, c70) 을 사용하여 최대 배팅을 \$10–\$70 으로 제한한다. 높은 상한은 라운드당 더 큰 손실을 허용하여 객관적 BK 위험을 증가시킨다. 모델의 내부 BK 확률이 제한 수준에 따라 선형적으로 스케일링된다면, BK 표상은 단순한 이진 BK/Safe 구분이 아닌 연속적 위험 크기를 인코딩하는 것이다.

Table 17: 배팅 제한 → BK 확률 (교차 모델, IC SAE L22)

Constraint	Gemma BK prob	LLaMA BK prob	Gemma Actual BK%	LLaMA Actual BK%
c10	0.000	0.057	0.0%	—
c30	0.056	0.113	5.2%	—
c50	0.212	0.233	16.8%	—
c70	0.270	0.360	21.0%	—

	Gemma	LLaMA
Linear r	**0.979**	**0.987**
p	0.021	0.013

두 모델 모두 거의 완벽한 선형 관계를 보인다 ($r > 0.97$, $p < 0.025$). BK 표상은 객관적 위험 노출(배팅 상한)에 따라 연속적으로 스케일링된다. LLaMA의 약간 더 높은 r (0.987 대 0.979)과 더 가파른 기울기(c10: 0.057에서 c70: 0.360)는 더 민감한 위험 스케일링 메커니즘을 나타낸다.

보충: 변동/고정 BK 방향 코사인 (두 모델, 두 수준)

변동 BK 방향과 고정 BK 방향 간의 방향 코사인(direction cosine)은 보충적 증거를 제공한다. 양의 코사인은 파산 발생 시 두 배팅 유형이 활성화를 동일한 방향으로 밀어냄을 나타낸다.

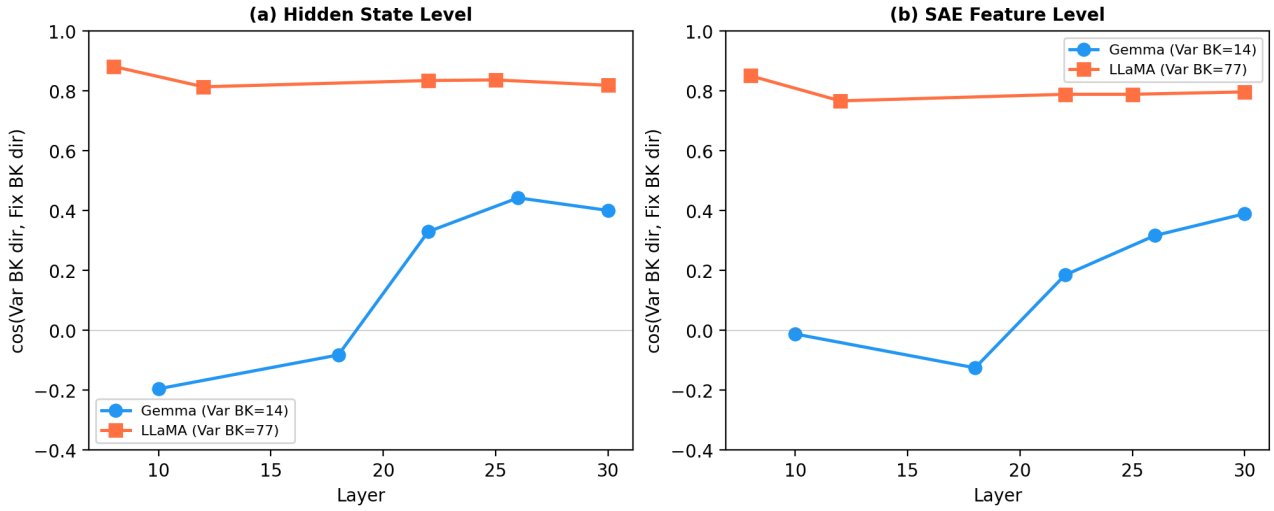

Figure 4: 변동/고정 BK 방향 코사인. (a) 은닉 상태 수준: LLaMA cos> 0.81 (모든 층); Gemma는 음에서 양으로 수렴 (얕은 → 깊은). (b) SAE 피처 수준: 동일 패턴 재현. Gemma의 낮은 코사인은 Variable BK= 14 표본 크기를 반영.

그림 4 해석: LLaMA IC (주황색)는 모든 층에서 일관되게 높은 코사인(HS에서 > 0.81, SAE에서 > 0.77)을 보이며, 변동 및 고정 BK 표상 간의 강한 방향적 수렴을 나타낸다. Gemma IC (파란색)는 두 표상 수준 모두에서 얕은-음 → 깊은-양 기울기를 보이며, L30에서 $\cos \approx 0.39$로 수렴한다. Gemma–LLaMA 간 불일치는 표본 크기로 설명된다: Gemma Variable BK= 14 (노이즈가 큰 방향 추정) 대 LLaMA Variable BK= 77 (안정적 추정). Gemma의 깊은 층 수렴은 동일한 결론을 뒷받침한다: 충분한 처리 깊이에서 변동 및 고정 BK 방향이 정렬된다.

4.5 RQ3 종합

네 가지 분석이 조건 불변적 BK 표상을 확립한다:

RQ3 증거 요약

Evidence	Strength	Key Number
Cross-bet-type transfer F1 (V10 NEW)	**Strong**	AUC 0.736–0.927, all $p = 0.000$ (both models)
Common BK features across bet types (V10 NEW)	**Strong**	415 features, balanced 213/202
LLaMA IC Var/Fix cosine > 0.81	**Strong**	All 5 layers, balanced sample
Shared BK neurons ∼33–37% (IC)	**Strong**	Cross-model consistent
G-prompt BK alignment (both models)	**Strong**	cos +0.634 to +0.850 at L22
Bet constraint linear mapping	**Strong**	$r = 0.979$ (Gemma), 0.987 (LLaMA)
Balance confound control	**Strong**	99.7–101% retained

V10은 F1 교차 배팅 유형 전이 분석을 통해 RQ3를 결정적으로 진전시킨다. V9는 간접적 증거(코사인 유사도, 공유 뉴런 비율)를 제공했고, V10은 직접적 증거(성공적 분류 전이)를 제공한다. 고정 배팅 BK 게임만으로 훈련된 분류기가 변동 배팅 BK 게임을 AUC 0.927까지 예측할 수 있으며 (반대 방향도 마찬가지), 이는 BK 표상이 배팅 자율성에 대해 기능적으로 불변적임을 입증한다.

5 NMT 논문 3.2 절에 대한 시사점

논문의 3.2 절은 활성화 패칭 (Activation patching) 을 통해 LLaMA SM 에서 112 개의 인과적 피처 (causal features) 를 식별하였으며, 안전 피처는 L4–L19 에 집중되고 위험 피처는 L24+ 에 집중된다. 이 피처들은 양방향 인과 효과와 목표 추구 대 중단 어휘와의 의미적 연관을 보인다. V10 은 이 단일 모델, 단일 도메인 발견을 세 방향으로 확장한다.

1. 교차 모델 검증. 112 개의 인과적 피처는 LLaMA SM 에서 식별되었다. V10 은 Gemma 가 거의 동일한 BK 분류 (0.976 대 0.974), 균형 잡힌 촉진/억제 구조를 가진 600 개의 보편적 BK 뉴런, 65.2% 의 결과-독립적 피처를 달성함을 보여준다. 이는 인과적 피처가 LLaMA 특이적 인공물이 아니라 두 아키텍처가 공유하는 속성을 반영함을 확립한다.

2. 교차 도메인 일반화. 인과적 피처는 슬롯머신 패러다임에서 식별되었다. V10 의 교차 도메인 전이 (Gemma IC→MW AUC 0.932; LLaMA MW→IC AUC 0.805) 와 요인 분해 (65–76% 패러다임 독립적) 는 BK 표상이 특정 도박 도메인을 넘어 일반화됨을 입증한다. BK 의 신경적 기반은 과제 특이적 패턴 매칭이 아닌, 도메인 일반적 위험 계산 (domain-general risk computation) 을 반영한다.

3. 교차 조건 견고성. F1 교차 배팅 유형 전이 (AUC 0.736–0.927, 모두 $p = 0.000$) 는 BK 표상이 고정/변동 자율성 조작에 대해 견고함을 입증한다. 선형 배팅 제한 매핑 ($r > 0.97$) 과 결합하면, 인과적 피처가 위험 노출에 따라 연속적으로 스케일링되고 표면적 과제 매개변수에 불변적인 표상 공간 내에서 작동함을 보여준다.

이 세 가지 확장은 3.2 절을 단일 모델, 단일 도메인 인과 분석에서 다중 모델, 다중 도메인, 다중 조건 메커니즘적 설명으로 변환한다.

6 한계점

6.1 BK 비율 이질성

	Gemma IC	LLaMA IC	Gemma SM	LLaMA SM	Gemma MW	LLaMA MW
BK%	10.8%	8.9%	2.7%	36.4%	1.7%	75.8%

LLaMA MW BK 비율 (75.8%) 은 Gemma MW(1.7%) 의 44× 이다. 행동 수준에서의 교차 모델 비교는 이러한 기저 비율 차이에 의해 교란된다. 분류 AUC(균형 클래스 가중치 사용) 는 이를 부분적으로 완화하지만, 저-BK 조건에서의 소표본 팽창으로 인해 모델 간 효과 크기 (Cohen's d) 비교는 여전히 신뢰할 수 없다.

6.2 상관적 증거

본 보고서의 모든 분석은 상관적이다. 논문의 112 개 인과적 피처는 활성화 패칭 (LLaMA SM 에서만) 에서 비롯된다. 교차 모델 및 교차 도메인 인과 검증 (Gemma 활성화 패칭, IC/MW 패칭) 은 보류 중이다. 전이 AUC 는 공유 표상을 입증하지만 인과적 필요성 (causal necessity) 을 확립하지는 않는다.

6.3 통계적 검정력 불균형

Analysis	Weakness
Gemma IC Variable BK	$n = 14$ (배팅 유형 비교에 대한 매우 낮은 검정력)
Gemma MW BK	$n = 54$ (MW 특이적 분석 제한)
LLaMA 2-paradigm sign-consistency	50% 우연 수준; 이항 검정에서 13/16 층이 NS

6.4 LLaMA 은닉 상태 층 커버리지

LLaMA 은닉 상태는 5개 층 (L8, L12, L22, L25, L30) 에서만 추출되며, 전체 32개 층에서 추출되지 않는다. 이 체크포인트 사이의 층 특이적 현상이 누락될 수 있다. Gemma는 더 넓은 층 커버리지를 가진다.

6.5 다중 비교 문제

FDR 보정은 개별 분석 (예: 보편적 뉴런 식별) 내에서 적용되지만, 전체 분석 집합에 걸쳐서는 적용되지 않는다. 모델, 층, 패러다임에 걸친 뉴런별 및 피처별 검정은 큰 총 검정 수를 생성한다. 효과 크기를 일차 증거로, p-값을 이차 증거로 취급해야 한다.

---

7 향후 과제

1. **Gemma 활성화 패칭**: Gemma의 600개 보편적 BK 뉴런과 상위 교차 도메인 피처가 BK 결과에 인과적으로 필요한지 검증. 교차 모델 인과 검증을 위한 핵심 실험.
2. **IC/MW 활성화 패칭**: SM에서 식별된 인과적 피처의 IC 및 MW에서의 인과 효과 테스트, 교차 도메인 인과 일반화를 직접 검증.
3. **Gemma 교차 배팅 유형 전이 (은닉 상태)**: SAE뿐만 아니라 Gemma 은닉 상태를 사용한 F1 분석 복제, 교차 배팅 유형 불변성의 모델 일반적 특성 확인.
4. **G-프롬프트 메커니즘 심층 분석**: G가 Gemma에서 20.75× BK 효과를 생성하지만 LLaMA에서는 1.26×만 생성하는 이유 조사. 코사인 정렬 차이 (0.850 대 0.634) 만으로는 16×의 행동적 격차를 설명하지 못함.
5. **LLaMA 3-패러다임 SAE 교차 도메인 일관성**: Gemma 7-층 부호 일관성 분석 (V9 Table 5) 을 IC+SM+MW를 사용한 LLaMA로 확장, 25% 3-패러다임 우연 수준에 대한 검정.

A V9에서 V10으로의 주요 추가 사항 요약

Table 18: V9에서 V10으로의 추가 사항

Analysis	V9 Status	V10 Addition
LLaMA MW data	Missing	**3,200 games, BK**= 2,426 **(75.8%)**
LLaMA MW classification	N/A	**AUC** 0.963 **(L16),** 0.96+ **all layers**
LLaMA 3-paradigm transfer	N/A	**MW→IC AUC** 0.805 **(L25)**
LLaMA 3-paradigm factor decomp	2-paradigm: 69.5%	**3-paradigm: 75.8%**
Cross-bet-type transfer (F1)	Not tested	**LLaMA: AUC** 0.736–0.927 **(all** p = 0.000)
Cross-bet-type transfer (F1)	Not tested	**Gemma SAE: AUC** 0.696–0.902 **(deep layers)**
Common BK features (bet-type)	Not quantified	**415 features (213 promoting, 202 inhibiting)**
LLaMA 2D BK subspace	Not computed	**IC AUC**= 0.901**, SM AUC**= 0.943
LLaMA G-prompt alignment	Behavioral only (1.26×)	$\cos(G_{\text{dir}}, BK_{\text{dir}})$**: L22**= +0.634**, L30**= +0.548
LLaMA bet constraint mapping	Not computed	$r = 0.987$**,** $p = 0.013$