LLM의 위험 의사결정에 대한 교차 모델, 교차 도메인 신경 기반 분석

"대형 언어 모델은 도박 중독에 빠질 수 있는가?"

이승필, 신동현, 이윤정, 김선동
GIST (광주과학기술원)

2026년 3월 22일

Contents

개요 **3**

핵심 요약 **3**

1 실험 설정 **4**
1.1 데이터 4
1.2 핵심 정의 4

2 RQ1: 두 모델이 공통적인 BK 패턴을 공유하는가? **4**
2.1 BK 분류 4
2.2 보편 BK 뉴런 5
2.3 요인 분해 5
2.4 RQ1 요약 6

3 RQ2: 도메인이 바뀌어도 BK 패턴이 유지되는가? **6**
3.1 교차 도메인 전이 6
3.2 공유 BK 부분공간 7
3.3 Hidden States vs SAE 전이 비교 7
3.4 RQ2 요약 7

4 RQ3: 배팅 조건이 바뀌어도 BK 패턴이 유지되는가? **8**
4.1 교차 배팅 유형 전이 (F1) 8
4.2 방향 코사인 및 공통 특성 8
4.3 G-프롬프트 및 배팅 제약 효과 9
4.4 RQ3 요약 9

5 NMT 논문 §3.2에 대한 함의 **9**

6 한계 **10**

7 다음 단계 **10**

개요

대형 언어 모델 (Large Language Model) 이 도박 과제에서 파산 (bankruptcy) 할 때—잔고가 0 이 될 때까지 반복적으로 배팅을 선택할 때—네트워크 내부에서는 무슨 일이 벌어지는가? 본 보고서는 이러한 내부 "파산 신호 (bankruptcy signal)" 가 서로 다른 모델, 도박 도메인, 실험 조건에 걸쳐 공유되는 보편적 속성인지, 아니면 각 설정마다 고유한 신경 패턴을 생성하는지 묻는다.

두 개의 트랜스포머 (transformer) 모델을 분석한다: **Gemma-2-9B-IT** (Google, 42 레이어, 3,584 차원) 와 **LLaMA-3.1-8B-Instruct** (Meta, 32 레이어, 4,096 차원). 각 모델은 세 가지 음의 기대값 도박 패러다임—Investment Choice (IC), Slot Machine (SM), Mystery Wheel (MW)—을 수행하여, 6 개 모델–패러다임 조합에 걸쳐 총 16,000 게임을 생성한다. 배팅 조건 (Fixed/Variable) 과 프롬프트 구성요소 (Goal, Money, Warning, Hint, Persona) 를 체계적으로 변화시킨다.

내부 표현 (internal representation) 을 두 수준에서 검토한다. **은닉 상태 (hidden states)** 는 각 트랜스포머 레이어의 전체 활성화 벡터를 포착한다. **SAE 특성 (SAE features)** 은 GemmaScope (131K features/layer) 와 LlamaScope (32K features/layer) 를 통해 추출한 은닉 상태의 희소하고 해석 가능한 분해이다. 분류에는 StandardScaler → PCA(50) → Logistic Regression (balanced, C=1.0) 을 사용하며, 5-fold 층화 교차검증 (stratified cross-validation) 을 적용한다. 200 회 순열 검정 (permutation test) 을 통한 전이 AUC(transfer AUC) 로 통계적 유의성을 확인한다.

세 가지 연구 질문:

- **RQ1**: Gemma 와 LLaMA 가 공통적인 파산 (BK) 패턴을 공유하는가?
- **RQ2**: 도박 도메인이 바뀌어도 BK 패턴이 유지되는가?
- **RQ3**: 배팅 조건이 바뀌어도 BK 패턴이 유지되는가?

핵심 요약

RQ1—두 모델 모두 거의 동일한 정확도와 균형 잡힌 신경 구조로 파산을 인코딩한다. Gemma 와 LLaMA 는 모든 패러다임에서 BK 분류 AUC 가 0.006 이내로 일치한다 (0.954–0.976). L22 에서 Gemma 는 600 개, LLaMA 는 1,334 개의 보편 BK 뉴런 (universal BK neuron) 을 가지며, 두 모델 모두 촉진 (promoting) 과 억제 (inhibiting) 뉴런의 수가 거의 동일하다. 배팅 유형과 패러다임을 통제한 후에도, SAE 특성의 65–76% 가 BK-유의 (permutation p=0.000 vs 귀무 ∼1%) 하다.

RQ2—한 도메인에서 학습된 BK 분류기가 다른 도메인의 파산을 예측한다. Gemma IC→MW 전이 (transfer) 는 AUC 0.932 (L18) 에 도달하며, LLaMA MW→IC 는 0.805 (L25) 에 도달한다. 두 모델 모두 패러다임별 가중치 벡터 (weight vector) 가 거의 직교 (cosine ≈ 0.04) 함에도 이를 달성하며, 이는 BK 신호가 단일 방향이 아닌 공유된 저차원 부분공간 (low-dimensional subspace) 을 차지함을 나타낸다.

RQ3—Fixed-bet 파산으로 학습된 분류기가 Variable-bet 파산을 예측하며, 그 역도 성립한다. 교차 배팅 유형 전이 (cross-bet-type transfer) 는 모든 LLaMA 레이어에서 AUC 0.74–0.93 을 보인다 (모두 p=0.000). Gemma SAE 는 심층 레이어 (L30: 0.902) 에서 동일 패턴을 확인한다. 415 개 SAE 특성이 두 배팅 조건 모두에서 일관된 BK 효과 (동일 부호, d≥0.3) 를 보인다.

---

1 실험 설정

1.1 데이터

Table 1: 데이터셋 개요

패러다임	모델	게임 수	BK	BK%
IC	Gemma	1,600	172	10.8%
IC	LLaMA	1,600	142	8.9%
SM	Gemma	3,200	87	2.7%
SM	LLaMA	3,200	1,164	36.4%
MW	Gemma	3,200	54	1.7%
MW	LLaMA	3,200	2,426	75.8%

각 패러다임은 2 개의 배팅 유형 (Fixed/Variable) 과 32 개의 프롬프트 조합을 사용한다. IC 는 배팅 제약 (c10/c30/c50/c70) 도 추가로 변화시킨다. SM 과 MW 에서 LLaMA 의 BK 비율은 Gemma 보다 13–44 배 높으며, 이는 두 모델이 매우 다른 행동 전략을 취하면서도 동등한 정확도로 BK 정보를 인코딩함을 의미한다 (§2.1 참조).

1.2 핵심 정의

파산 (Bankruptcy, BK)
누적 손실로 잔고가 $0 에 도달한 상태. 주요 결과 변수 (outcome variable).

의사결정 지점 (Decision Point, DP)
각 게임에서 모델의 마지막 배팅/정지 결정 시점의 활성화 상태.

보편 BK 뉴런 (Universal BK neuron)
테스트된 모든 패러다임에서 BK 결과와의 상관이 FDR-유의 (BH, $p<0.01$) 하며 부호가 동일한 뉴런.

교차 도메인 전이 (Cross-domain transfer)
한 패러다임에서 BK 분류기를 학습하고 다른 패러다임에서 테스트. AUC $\gg 0.5$ 이며 순열 $p<0.05$ 이면 공유된 BK 구조를 나타냄.

교차 배팅 유형 전이 (Cross-bet-type transfer, F1)
Fixed-bet 게임에서 BK 분류기를 학습하고 Variable-bet 게임에서 테스트 (및 그 역).

---

2 RQ1: 두 모델이 공통적인 BK 패턴을 공유하는가?

2.1 BK 분류

두 모델 모두 각 최적 레이어에서 세 패러다임 전부에서 BK 분류 AUC > 0.95 를 달성한다.

Table 2: BK 분류 AUC

패러다임	Gemma	LLaMA	차이
SM	0.976 (L20)	0.974 (L8)	0.002
IC	0.960 (L30)	0.954 (L12)	0.006
MW	0.966 (L30)	0.963 (L16)	0.003

두 모델은 서로 다른 깊이에서 최고점을 보인다—Gemma 는 L20–L30, LLaMA 는 L8–L16—그러나 최적 AUC 값의 차이는 최대 0.006 이다. LLaMA MW 의 BK 비율 (75.8%) 이 Gemma MW(1.7%) 보다 44 배 높음에도 이러한 결과가 유지된다. 분류 파이프라인이 균형 클래스 가중치 (balanced class weights) 를 사용하므로, 이 동등성은 기저율 (base rate) 의 산물이 아니다. BK 정보는 두 아키텍처 모두에서 동등한 충실도 (fidelity) 로 존재한다.

2.2 보편 BK 뉴런

Table 3: 보편 BK 뉴런 (L22)

	Gemma (3-패러다임)	**LLaMA (2-패러다임)**
전체 뉴런 수	3,584	4,096
보편 BK 뉴런	600 (16.7%)	1,334 (32.6%)
촉진 / 억제	302 / 298	672 / 662

LLaMA 의 높은 수치는 주로 우연 기준선 (chance baseline) 의 차이를 반영한다: 2-패러다임 부호 일관성의 우연 기준선은 50% 인 반면, 3-패러다임은 25% 이다. 핵심 발견은 절대 수치가 아니라 **균형 비율**이다: 두 모델 모두 테스트된 모든 레이어 (L8–L30) 에서 거의 동일한 수의 촉진 뉴런과 억제 뉴런을 통해 BK 를 인코딩한다. 이러한 양방향 구조는 BK-촉진 신호와 BK-억제 신호가 공존하는 "밀고-당기기 (push-pull)" 메커니즘을 시사한다.

2.3 요인 분해

각 SAE 특성에 대해 OLS 회귀 (`feature ~ outcome + bet_type + paradigm`) 를 수행하여, 배팅 유형과 패러다임을 통제한 후 BK 결과가 독립적으로 기여하는지 검증한다.

Table 4: 결과-유의 특성

모델	**패러다임**	**특성 수**	**결과-유의**	**순열 귀무**
Gemma	IC+SM+MW	581	65.2% (379)	∼1%
LLaMA	IC+SM	1,418	69.5% (985)	∼1%
LLaMA	IC+SM+MW	1,056	75.8% (800)	∼1%

LLaMA 내에서, MW 를 세 번째 패러다임으로 추가하면 결과-유의 비율이 69.5% 에서 75.8% 로 증가하며, 이는 추가 도메인이 패러다임 특이적 잡음을 필터링하되 BK 신호를 희석하지 않음을 나타낸다. 세 분해 모두 순열 귀무 (∼1%) 를 60 배 이상 초과한다.

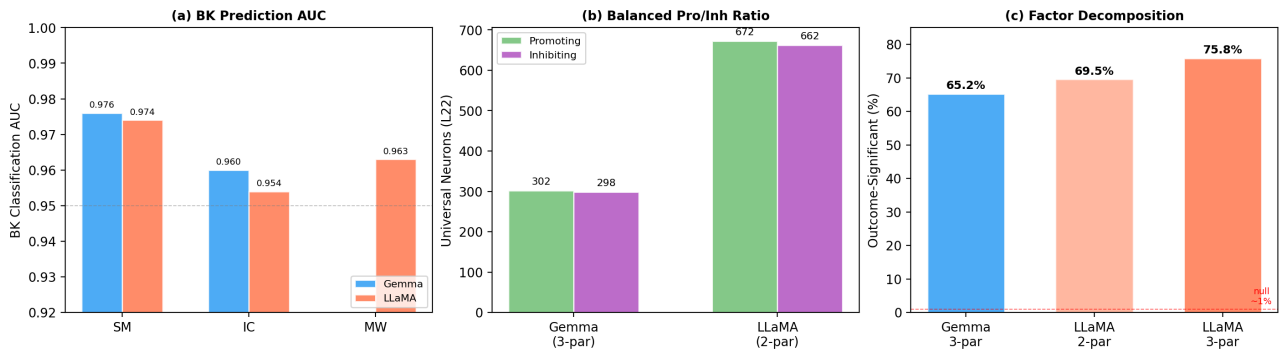

Figure 1: (a) 교차 모델 BK 분류 AUC. (b) 보편 BK 뉴런: 균형 잡힌 촉진/억제 비율. (c) 요인 분해: 65–76% 결과-유의 vs ∼1% 귀무.

2.4 RQ1 요약

BK 예측 정확도는 아키텍처 간 동등하다 (AUC 차이 ≤ 0.006). 두 모델 모두 균형 잡힌 촉진/억제 뉴런 구조를 유지한다. SAE 특성의 65–76%가 교란 변수와 독립적으로 BK를 인코딩한다. 이 세 관찰은 서로 다른 훈련 데이터와 모델 크기에도 불구하고 두 아키텍처에서 공유된 BK 표현(shared BK representation)이 발생함과 일치한다.

---

3 RQ2: 도메인이 바뀌어도 BK 패턴이 유지되는가?

3.1 교차 도메인 전이

Table 5: Gemma SAE 전이 (최적 레이어)

전이	AUC	p
IC → MW	0.932	0.000
IC → SM	0.913	0.000
SM → MW	0.867	0.000
MW → IC	0.853	0.000
SM → IC	0.646	0.000

Table 6: LLaMA 3-패러다임 전이 (최적 레이어)

전이	AUC	p
MW → IC	0.805	0.000
SM → IC	0.749	0.000
IC → MW	0.680	0.000
MW → SM	0.682	0.000
IC → SM	0.577	0.000

두 모델 모두 MW를 포함하는 전이에서 강한 성능을 보이며 (AUC 0.68–0.93), IC↔SM 전이는 상대적으로 약하고 레이어에 따라 달라진다. MW는 "허브(hub)" 패러다임으로 기능한다: MW에서 학습되거나 MW에 적용된 BK 패턴이 다른 도메인으로 잘 전이된다.

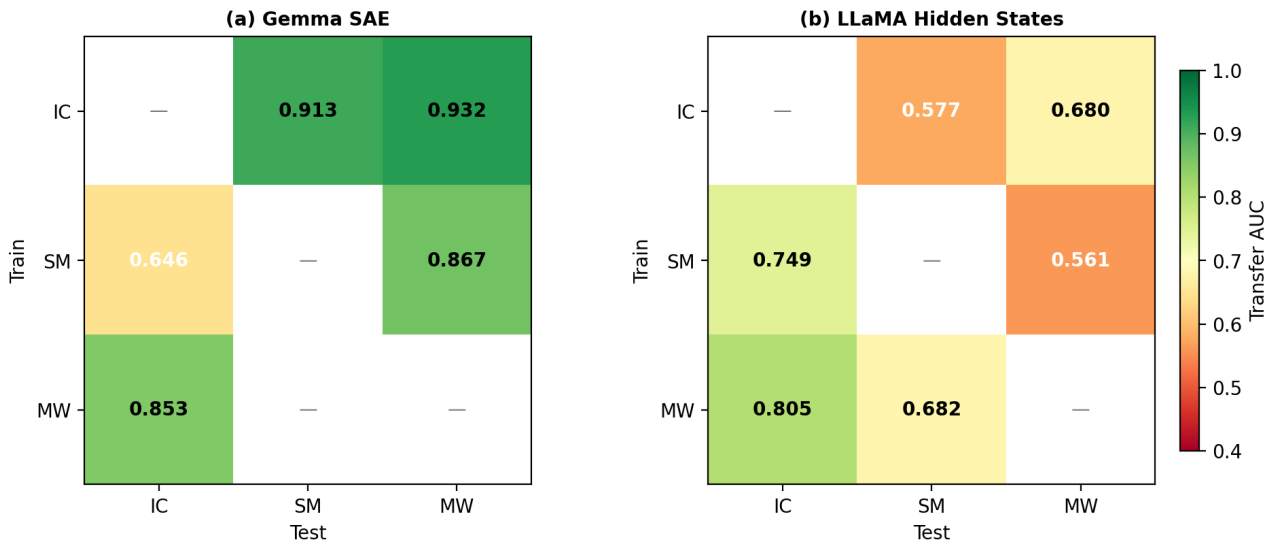

Figure 2: 교차 도메인 전이 히트맵. (a) Gemma SAE. (b) LLaMA hidden states. 녹색 = 높은 전이; 노란색/빨간색 = 약한 전이.

3.2 공유 BK 부분공간

패러다임별 분류기의 가중치 벡터가 거의 직교 (cosine ≈ 0.04) 함에도, 이 가중치 벡터들에 대한 PCA 로 추출한 저차원 부분공간 (low-dimensional subspace) 이 높은 AUC 를 달성한다.

Table 7: 공유 부분공간 성능

	Gemma (3D)	**LLaMA (2D)**
IC AUC	0.862	0.901
SM AUC	0.899	0.943
MW AUC	0.970	—
가중치 코사인	∼0.04	0.038

거의 직교하는 가중치 벡터에서 높은 부분공간 AUC 가 나온다는 것은, BK 신호가 단일 축에 집중되지 않고 다차원 부분공간에 분산되어 있음을 의미한다.

3.3 Hidden States vs SAE 전이 비교

Hidden states 가 대부분의 교차 도메인 전이 방향에서 SAE 보다 우수하다 (Gemma IC→SM: +0.247; SM→MW: +0.101; LLaMA SM→IC: +0.064). SAE 희소화 (sparsification) 가 교차 도메인 일관성을 상실할 수 있으며, 이는 BK 신호가 부분적으로 희소 분해가 폐기하는 분산적이고 낮은 크기의 활성화에 의존함을 시사한다.

3.4 RQ2 요약

교차 도메인 전이가 두 모델 모두에서 성공한다 (AUC 0.58–0.93, 모두 p=0.000). MW 가 가장 강한 허브 패러다임이다. 직교 가중치 벡터에도 불구하고 공유 저차원 부분공간이 BK 를 포착한다. BK 인코딩은 심층 레이어에서 도박 도메인 간에 일반화된다.

4 RQ3: 배팅 조건이 바뀌어도 BK 패턴이 유지되는가?

4.1 교차 배팅 유형 전이 (F1)

Fixed-bet 게임에서만 학습된 BK 분류기를 Variable-bet 게임에 적용하며, 그 역도 수행한다.

Table 8: LLaMA IC Hidden State 전이

레이어	Fix→Var AUC	Var→Fix AUC	Both p
L8	0.872	0.842	0.000
L12	0.772	0.927	0.000
L22	0.736	0.912	0.000
L30	0.819	0.911	0.000

Table 9: Gemma IC SAE 전이

레이어	Fix→Var AUC	Var→Fix AUC	Both p
L18	0.808	0.726	0.000
L30	0.902	0.696	0.000
L10	NS	NS	—

LLaMA 에서는 모든 레이어와 양방향 모두 p=0.000 을 보인다. Var→Fix 전이 (0.84–0.93) 가 Fix→Var(0.74–0.87) 보다 일관되게 강한데, 이는 Variable 게임이 Fixed BK 영역을 포괄하는 더 넓은 활성화 공간을 탐색하기 때문일 수 있다. Gemma 에서는 심층 레이어가 성공하나 (L30: Fix→Var 0.902) 얕은 레이어 (L10) 는 실패하며—이는 교차 조건 전이에 심층 표현이 필요하다는 일반적 패턴과 일치한다. Gemma IC 는 Variable BK 사례가 14 건에 불과하여, Gemma 특이적 배팅 유형 분석의 통계적 검정력 (statistical power) 이 제한됨에 유의한다.

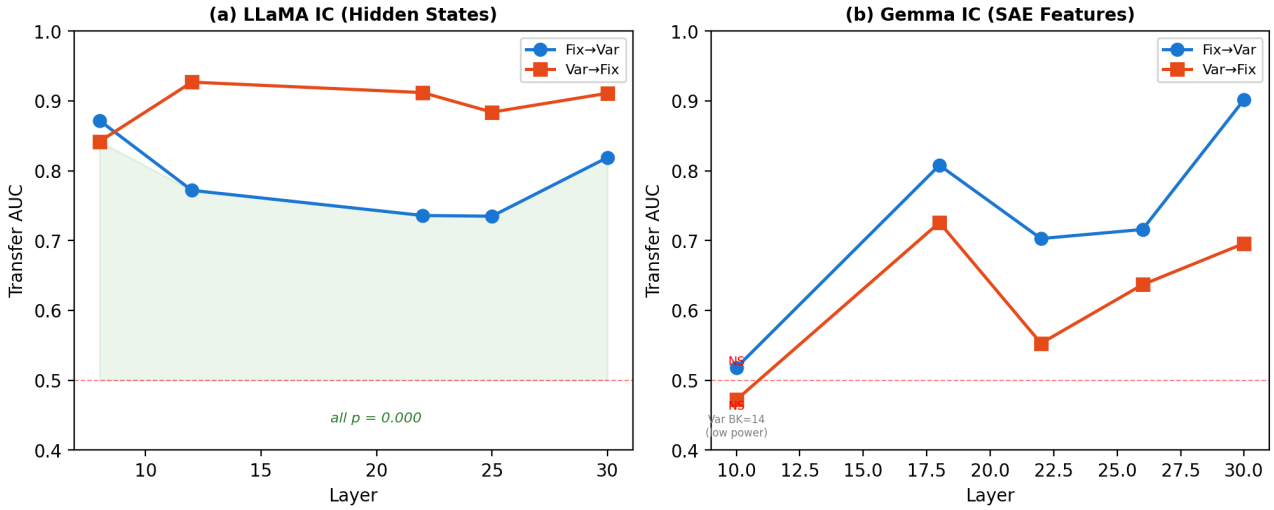

Figure 3: 교차 배팅 유형 전이. (a) LLaMA: 모든 레이어, 양방향, 모두 p=0.000. (b) Gemma SAE: 심층 레이어 성공; L10 실패.

4.2 방향 코사인 및 공통 특성

Variable BK 방향과 Fixed BK 방향 사이의 코사인 유사도 (cosine similarity) 가 보완적 증거를 제공한다. LLaMA IC 는 모든 hidden state 레이어에서 cos > 0.81, SAE 수준에서 cos 0.77–0.85 를 보인다. Gemma

IC는 얕은 레이어에서 음의 값으로 시작하여 L30에서 cos ∼0.39로 수렴하며—Variable BK 표본 크기 (n=14)로 인해 약하다.

SAE L22에서 415개 LLaMA 특성 (및 35개 Gemma 특성)이 두 배팅 조건 모두에서 $d \geq 0.3$이며 동일 부호를 보인다. 균형 잡힌 촉진/억제 비율 (LLaMA: 213/202)은 §2.2의 보편 뉴런 구조를 반영한다.

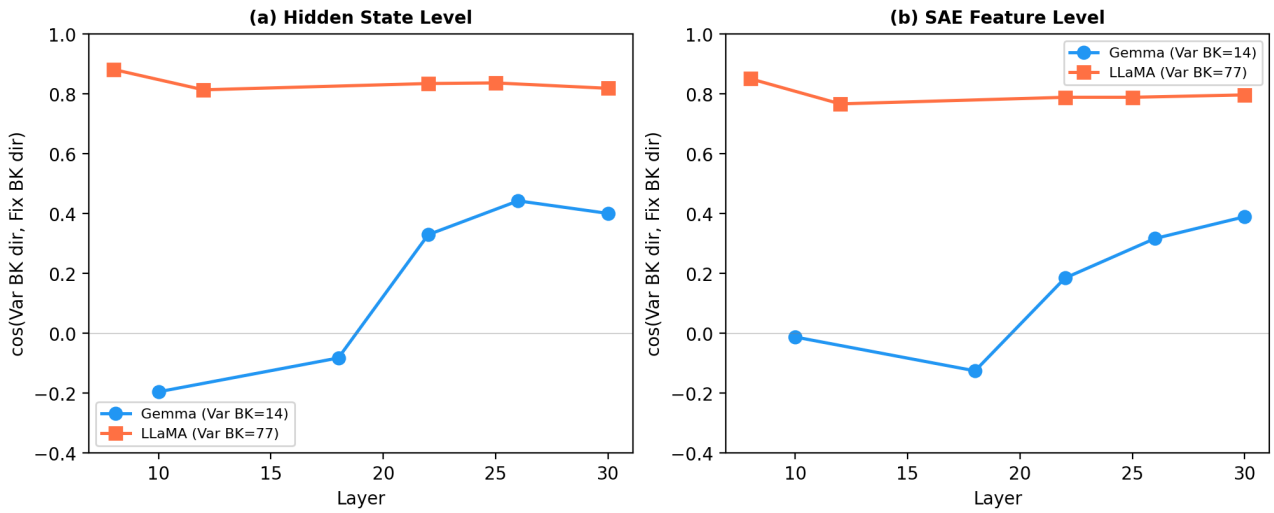

Figure 4: Var/Fix 방향 코사인. (a) hidden state 수준. (b) SAE 수준. LLaMA cos>0.77 전 레이어; Gemma는 심층에서 수렴.

4.3 G-프롬프트 및 배팅 제약 효과

G (Goal-setting) 프롬프트는 두 모델 모두에서 활성화를 BK 방향으로 이동시킨다 (Gemma SM에서 cos = +0.85, LLaMA SM에서 L22 기준 +0.63). 배팅 제약 (c10→c70)은 BK 확률에 선형적으로 대응한다 (Gemma r=0.979, LLaMA r=0.987; 단, n=4 데이터 포인트로 이 선형 주장의 강도가 제한됨에 유의). 이러한 관찰은 BK 표현이 이진적 BK/Safe 구분이 아닌 연속적 위험 크기 (continuous risk magnitude)를 인코딩함을 시사한다.

4.4 RQ3 요약

F1 교차 배팅 유형 전이 분석은 Fixed와 Variable 배팅 조건이 심층 레이어에서 동일한 기저 BK 표현을 공유한다는 직접적 증거를 제공한다. 방향 코사인, 공통 특성, G-프롬프트 정렬이 모두 같은 방향을 가리킨다. BK 인코딩은 두 모델 모두에서 Fixed/Variable 조작에 대해 강건하다.

---

5 NMT 논문 §3.2에 대한 함의

논문의 §3.2는 활성화 패칭 (activation patching)을 통해 LLaMA SM에서 112개의 인과적 특성 (causal features)을 식별하며, 안전 특성 (safe features)은 L4–L19에, 위험 특성 (risky features)은 L24+에 위치한다. 본 분석은 해당 단일 모델, 단일 도메인 발견을 세 방향으로 확장한다:

교차 모델 (Cross-model): Gemma는 거의 동일한 BK 분류 성능 (0.976 vs 0.974)과 동일한 균형 촉진/억제 뉴런 구조를 보인다. 112개 인과적 특성은 LLaMA 특이적 산물이 아니라 두 아키텍처 모두에 존재하는 속성을 반영할 가능성이 높다.

교차 도메인 (Cross-domain): BK 분류기가 IC, SM, MW 간에 AUC 최대 0.932로 전이된다. 요인 분해는 특성의 65–76%가 패러다임과 독립적으로 BK를 인코딩함을 보인다. SM에서 식별된 인과적 특성은 다른 도박 도메인으로 일반화될 가능성이 높다.

교차 조건 (Cross-condition): 교차 배팅 유형 전이 (AUC 0.74–0.93) 는 BK 표현이 Fixed/Variable 조작에 강건함을 입증한다—이는 논문의 핵심 행동 발견 (Variable 배팅이 파산을 증가시킴) 을 생성하는 바로 그 조작이다. 행동 결과가 분기하는 가운데서도 신경 표현은 안정적으로 유지된다.

---

6 한계

1. **상관적 증거만 존재.** 본 보고서의 모든 분석은 상관적 (correlational) 이다. 활성화 패칭을 통한 인과적 검증은 LLaMA SM(논문 §3.2) 에서만 수행되었다. 교차 모델 및 교차 도메인 인과 검증은 보류 중이다.
2. **표본 크기 불균형.** Gemma IC 는 Variable BK 사례가 14 건에 불과하여, Gemma 배팅 유형 분석의 검정력이 심각하게 제한된다. Gemma MW 는 54 건의 BK 를 가진다. LLaMA MW 는 2,426 건 BK(75.8%)—이 높은 기저율에서는 사소한 분류기도 좋은 성능을 보인다; 균형 클래스 가중치가 부분적으로 완화하지만, 보완적 지표 (balanced accuracy, F1) 가 주장을 강화할 것이다.
3. **레이어 범위.** LLaMA hidden states 는 5 개 레이어 (L8, L12, L22, L25, L30) 에서 추출되며 전체 32 개가 아니다. 이 체크포인트 사이의 레이어 특이적 현상이 누락될 수 있다.
4. **배팅 제약 선형성.** r=0.979/0.987 선형 매핑은 4 개 데이터 포인트 (c10, c30, c50, c70) 에서만 계산된다. df=2 이므로, 무작위 관계도 빈번하게 선형으로 나타날 수 있다.
5. **공통 BK 특성.** 415 개 공통 특성 (두 배팅 유형 모두에서 $d \geq 0.3$, 동일 부호) 은 순열 귀무 (permutation null) 비교가 없다. 이 기준을 우연히 충족하는 특성의 기대 수가 계산되지 않았다.
6. **다중 비교.** FDR 보정은 개별 분석 내에서 적용되지만 전체 분석 세트에 걸쳐서는 적용되지 않는다. 효과 크기 (effect size) 를 일차적 증거로 다루어야 한다.
7. **두 모델만 분석.** 다른 아키텍처 (예: Qwen, Mistral) 로의 일반화는 검증되지 않았다.

---

7 다음 단계

1. **Gemma 활성화 패칭**: Gemma 의 600 개 보편 BK 뉴런이 BK 결과에 인과적으로 영향을 미치는지 검증하여, 교차 모델 인과적 일반화를 확인한다.
2. **IC/MW 활성화 패칭**: SM 에서 식별된 인과적 특성을 다른 패러다임에서 검증한다.
3. **공통 특성에 대한 순열 귀무**: 레이블 순열 하에서 두 배팅 유형 모두 $d \geq 0.3$ 을 충족하는 특성의 기대 수를 계산한다.
4. **고-BK 조건에 대한 balanced accuracy**: LLaMA MW(75.8% BK) 에 대해 AUC 와 함께 balanced accuracy 및 F1 을 보고한다.
5. **G-프롬프트 메커니즘**: 유사한 방향 정렬에도 불구하고 존재하는 16 배 행동 격차 (Gemma G: 20.75 배 vs LLaMA G: 1.26 배) 를 조사한다.