LLM 의위험의사결정에대한 교차모델, 교차도메인신경기반분석

"대규모언어모델은도박중독에걸릴수있는가?"

이승필, 신동현, 이윤정, 김선동
GIST (광주과학기술원)

2026 년 3 월 25 일

Contents

개요 **3**

핵심요약 **3**

1 실험설계 **4**
1.1 데이터 4
1.2 주요정의 4

2 RQ1: 두모델이공통된 BK 패턴을공유하는가? **4**
2.1 BK 분류 4
2.2 보편적 BK 뉴런 5
2.3 요인분해 (Factor Decomposition) 5
2.4 RQ1 요약 6

3 RQ2: 도메인이바뀌어도 BK 패턴이유지되는가? **6**
3.1 교차도메인전이 6
3.2 공유 BK 부분공간 (Shared BK Subspace) 7
3.3 은닉상태 vs SAE 의전이성능 7
3.4 RQ2 요약 7

4 RQ3: 베팅조건이바뀌어도 BK 패턴이유지되는가? **8**
4.1 교차베팅유형전이 (F1) 8
4.2 방향코사인과공통특징 8
4.3 G-프롬프트와베팅제약효과 9
4.4 RQ3 요약 9

5 NMT 논문 §3.2 에대한함의 **9**

6 강건성검증 **10**

6.1 PCA 차원민감도 10
6.2 분류기비교 10
6.3 강건성요약 11

7 인과적검증: BK 방향조향 11
7.1 뉴런수준제거 (영결과) 11
7.2 방향조향방법 11
7.3 조향결과 11
7.4 무작위방향통제와주의사항 12
7.5 상관적증거와인과적증거의연결 12
7.6 인과적검증요약 13

8 한계 13

9 향후과제 13

개요

대규모언어모델 (Large Language Model) 이도박과제에서파산 (bankruptcy) 할때—잔고가 0 이될때까지반복적으로베팅을선택할때—네트워크내부에서는무엇이일어나는가? 본보고서는이내부 "파산신호 (bankruptcy signal)" 가서로다른모델, 도박도메인, 실험조건에걸쳐공유되는보편적속성인지, 아니면각설정마다고유한신경패턴을생성하는지를묻는다.

두개의트랜스포머 (Transformer) 모델을분석한다: **Gemma-2-9B-IT** (Google, 42 층, 3,584 차원) 과 **LLaMA-3.1-8B-Instruct** (Meta, 32 층, 4,096 차원). 각모델은세가지음의기대값도박패러다임—투자선택 (Investment Choice, IC), 슬롯머신 (Slot Machine, SM), 미스터리휠 (Mystery Wheel, MW)—을수행하며, 6 개모델–패러다임조합에걸쳐총 16,000 개게임을진행한다. 베팅조건 (고정/가변) 과프롬프트구성요소 (목표, 자금, 경고, 힌트, 페르소나) 를체계적으로조작한다.

내부표상 (internal representation) 은두수준에서검토한다. **은닉상태 (Hidden states)** 는각트랜스포머층의전체활성화벡터를포착한다. **SAE 특징 (SAE features)** 은이은닉상태의희소하고해석가능한분해로, GemmaScope (131K 특징/층) 와 LlamaScope (32K 특징/층) 를통해추출된다. 분류에는 StandardScaler → PCA(50) → 로지스틱회귀 (Logistic Regression, 균형가중치, C=1.0) 와 5-fold 층화교차검증을사용한다. 전이 AUC(Transfer AUC) 에 200 회순열검정 (permutation test) 을적용하여통계적유의성을확인한다.

세가지연구질문:

- **RQ1**: Gemma 와 LLaMA 는공통된파산 (BK) 패턴을공유하는가?
- **RQ2**: 도박도메인이바뀌어도 BK 패턴이유지되는가?
- **RQ3**: 베팅조건이바뀌어도 BK 패턴이유지되는가?

V11 은 V10 을두가지새로운분석으로확장한다: (1) 분류파이프라인의강건성검증 (PCA 차원민감도및분류기비교), (2) LLaMA 에서의 BK 방향조향 (steering) 을통한인과적검증.

핵심요약

RQ1—두모델모두거의동일한정확도와균형잡힌신경구조로파산을인코딩한다. Gemma 와 LLaMA 는모든패러다임에서 BK 분류 AUC 차이가 0.006 이내이다 (0.954–0.976). L22 에서 Gemma 는 600 개, LLaMA 는 1,334 개의보편적 BK 뉴런을가지며, 촉진 (promoting) 과억제 (inhibiting) 뉴런의수가대략동일하다. 베팅유형과패러다임을통제한후에도 SAE 특징의 65–76% 가 BK 에유의하다 (순열검정 p=0.000 vs 귀무가설 ∼1%).

RQ2—한도메인에서훈련된 BK 분류기가다른도메인의파산을예측한다. Gemma IC→MW 전이 AUC 0.932 (L18); LLaMA MW→IC 0.805 (L25). 두모델모두거의직교하는패러다임별가중치벡터 (코사인 ≈ 0.04) 에도불구하고이를달성하며, BK 신호가단일방향이아닌공유된저차원부분공간 (subspace) 을차지함을시사한다.

RQ3—고정베팅파산으로훈련된분류기가가변베팅파산을예측하며, 그반대도성립한다. 교차베팅유형전이는모든 LLaMA 층에서 AUC 0.74–0.93 을산출한다 (모두 p=0.000). Gemma SAE 도심층에서이패턴을확인한다 (L30: 0.902). 415 개 SAE 특징이두베팅조건모두에서일관된 BK 효과를보인다 (동일부호, d≥0.3).

강건성—분류결과는 PCA 차원수와분류기선택에둔감하다. 6 개데이터셋중 4 개에서 AUC 가 PCA=50 에서포화되며, 나머지 2 개에서는 PCA=50 이 PCA 미적용보다우수하다 (BK 표본이적어과적합가능성이높은경우). 로지스틱회귀, MLP, SVM-RBF 간 AUC 차이가모든 6 개데이터셋에서 0.007 이내로, BK 표상의선형분리가능성 (linear separability) 을확인한다.

인과적검증—BK 방향벡터가 LLaMA 의도박행동에인과적영향을미친다. L22 의잔차스트림 (residual stream) 에 BK 방향을추가하면단조적용량-반응 (dose-response) 이나타난다: BK 비율이 34% (α=−2) 에서 52% (α=+2) 로증가하며, Spearman ρ=0.927 (p=0.003). 뉴런수준제거 (ablation) 는유의한효과를보이지않아, BK 가분산표상 (distributed representation) 임을확인한다. 무작위방향통제 (random direction control) 는비특이적교란효과를완전히배제하기위해다중알파검정이필요하다.

1 실험설계

1.1 데이터

Table 1: 데이터셋개요

패러다임	모델	게임수	BK	BK%
IC	Gemma	1,600	172	10.8%
IC	LLaMA	1,600	142	8.9%
SM	Gemma	3,200	87	2.7%
SM	LLaMA	3,200	1,164	36.4%
MW	Gemma	3,200	54	1.7%
MW	LLaMA	3,200	2,426	75.8%

각패러다임은 2 가지베팅유형 (고정/가변) 과 32 가지프롬프트조합을사용한다. IC 는추가로베팅제약 (c10/c30/c50/c70) 을변형한다. SM 과 MW 에서 LLaMA 의 BK 비율은 Gemma 보다 13–44 배높으며, 이는두모델이매우다른행동전략을채택하면서도 BK 정보를동등한정확도로인코딩함을의미한다 (§2.1 참조).

1.2 주요정의

파산 (Bankruptcy, BK)
누적손실로잔고가 $0 에도달하는것. 주요결과변수이다.

의사결정시점 (Decision Point, DP)
각게임에서모델이베팅또는중단을결정하는최종시점의활성화상태이다.

보편적 BK 뉴런 (Universal BK neuron)
검사한모든패러다임에서 BK 결과와의상관이 FDR-유의하고 (BH, $p<0.01$) 동일한부호를가진뉴런이다.

교차도메인전이 (Cross-domain transfer)
한패러다임에서 BK 분류기를훈련하고다른패러다임에서테스트한다. 순열검정 $p<0.05$ 에서 AUC $\gg$ 0.5 이면공유된 BK 구조를시사한다.

교차베팅유형전이 (Cross-bet-type transfer, F1)
고정베팅게임에서 BK 분류기를훈련하고가변베팅게임에서테스트한다 (및그반대).

BK 방향벡터 (BK direction vector)
특정층에서평균 BK 은닉상태와평균 Safe 은닉상태의차이. 조향 (steering) 실험에사용된다 (§7).

2 RQ1: 두모델이공통된 BK 패턴을공유하는가?

2.1 BK 분류

두모델모두각각의최적층에서세패러다임모두 BK 분류 AUC $>$ 0.95 를달성한다.

Table 2: BK 분류 AUC

패러다임	Gemma	LLaMA	차이
SM	0.976 (L20)	0.974 (L8)	0.002
IC	0.960 (L30)	0.954 (L12)	0.006
MW	0.966 (L30)	0.963 (L16)	0.003

두모델의최적깊이는다르다—Gemma 는 L20–L30, LLaMA 는 L8–L16—그러나최고 AUC 값의차이는최대 0.006 이다. 이는 LLaMA MW 의 BK 비율 (75.8%) 이 Gemma MW(1.7%) 보다 44 배높음에도불구하고성립한다. 분류파이프라인은균형클래스가중치를사용하므로, 이동등성은기저율 (base rate) 의인위적산물이아니다. BK 정보는두아키텍처모두에서비슷한충실도로존재한다.

2.2 보편적 BK 뉴런

Table 3: 보편적 BK 뉴런 (L22)

	Gemma (3-패러다임)	LLaMA (2-패러다임)
총뉴런수	3,584	4,096
보편적 BK 뉴런	600 (16.7%)	1,334 (32.6%)
촉진 / 억제	302 / 298	672 / 662

LLaMA 의더높은수는주로다른우연수준을반영한다: 2-패러다임부호일관성은 50% 우연기저선인반면, 3-패러다임은 25% 이다. 핵심발견은절대수가아니라 **균형비율**이다: 두모델모두검사한모든층 (L8–L30) 에서촉진과억제뉴런의수가대략동일하다. 이양방향구조는 BK-촉진신호와 BK-억제신호가공존하는 "밀기-당기기 (push-pull)" 메커니즘을시사한다.

2.3 요인분해 (Factor Decomposition)

각 SAE 특징에대해 OLS 회귀 (`feature ∼ outcome + bet_type + paradigm`) 를수행하여, 베팅유형과패러다임을통제한후 BK 결과가독립적으로기여하는지검정한다.

Table 4: 결과-유의특징

모델	패러다임	특징수	결과-유의	순열귀무
Gemma	IC+SM+MW	581	65.2% (379)	∼1%
LLaMA	IC+SM	1,418	69.5% (985)	∼1%
LLaMA	IC+SM+MW	1,056	75.8% (800)	∼1%

LLaMA 내에서 MW 를세번째패러다임으로추가하면결과-유의비율이 69.5% 에서 75.8% 로증가하며, 이는추가도메인이패러다임특이적잡음 (noise) 을걸러내되 BK 신호를희석하지않음을나타낸다. 세분해모두순열귀무가설 (∼1%) 을 60 배이상초과한다.

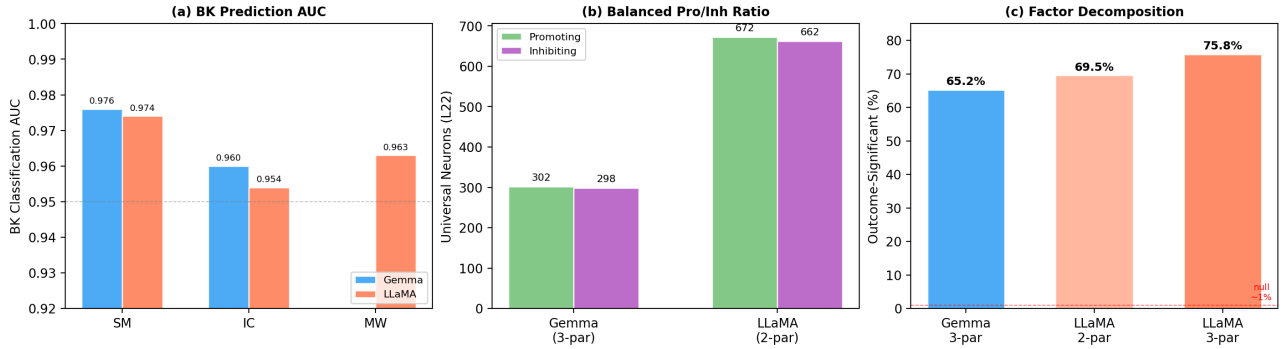

Figure 1: (a) 교차모델 BK 분류 AUC. (b) 보편적 BK 뉴런: 촉진/억제균형비율. (c) 요인분해: 결과-유의 65–76% vs 귀무 ∼1%.

2.4 RQ1 요약

BK 예측정확도는아키텍처간에동등하다 (AUC 차이 ≤ 0.006). 두모델모두균형잡힌촉진/억제뉴런구조를유지한다. SAE 특징의 65–76% 가교란변수와무관하게 BK 를인코딩한다. 이세관찰은서로다른훈련데이터와모델크기에도불구하고두아키텍처에서공유된 BK 표상이발생함을시사한다.

---

3 RQ2: 도메인이바뀌어도 BK 패턴이유지되는가?

3.1 교차도메인전이

Table 5: Gemma SAE 전이 (최적층)

전이	AUC	p
IC → MW	0.932	0.000
IC → SM	0.913	0.000
SM → MW	0.867	0.000
MW → IC	0.853	0.000
SM → IC	0.646	0.000

Table 6: LLaMA 3-패러다임전이 (최적층)

전이	AUC	p
MW → IC	0.805	0.000
SM → IC	0.749	0.000
IC → MW	0.680	0.000
MW → SM	0.682	0.000
IC → SM	0.577	0.000

두모델모두 MW 와관련된전이에서강한성능을보이며 (AUC 0.68–0.93), IC↔SM 전이는상대적으로약하고층에따라달라진다. MW 는 “허브 (hub)” 패러다임으로기능한다: MW 에서학습되거나 MW 에적용되는 BK 패턴이다른도메인으로잘전이된다.

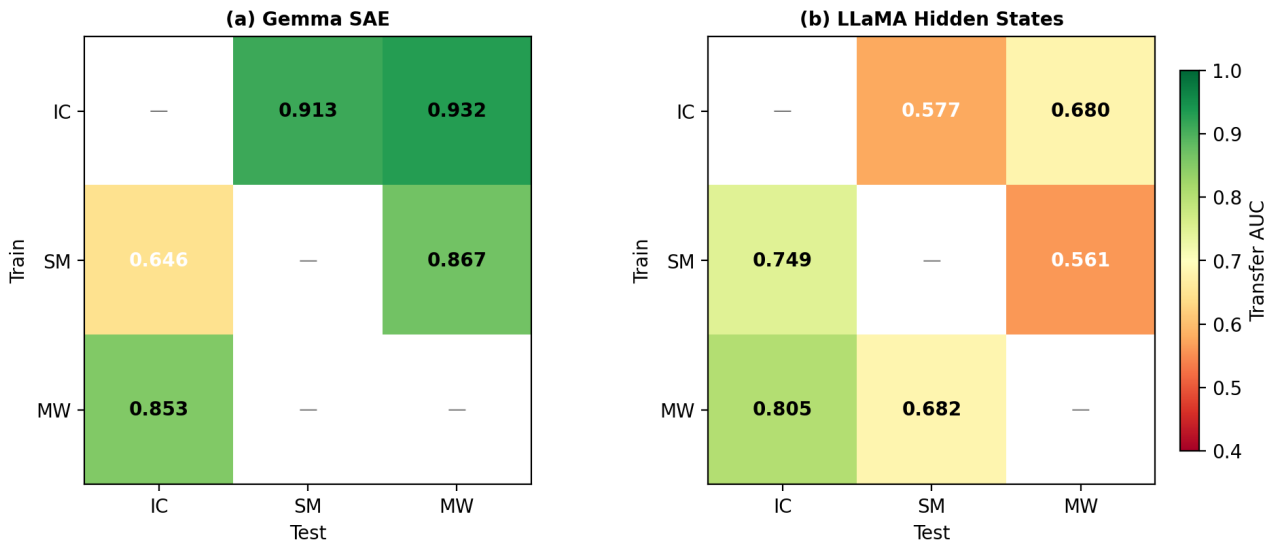

Figure 2: 교차도메인전이히트맵. (a) Gemma SAE. (b) LLaMA 은닉상태. 녹색 = 높은전이; 노란색/빨간색 = 약한전이.

3.2 공유 BK 부분공간 (Shared BK Subspace)

패러다임별분류기의가중치벡터는거의직교하지만 (코사인 ≈ 0.04), 이가중치벡터에 PCA 를적용하여추출한저차원부분공간은높은 AUC 를달성한다.

Table 7: 공유부분공간성능

	Gemma (3D)	LLaMA (2D)
IC AUC	0.862	0.901
SM AUC	0.899	0.943
MW AUC	0.970	—
가중치코사인	∼0.04	0.038

거의직교하는가중치벡터에도불구하고높은부분공간 AUC 를달성한다는것은, BK 신호가단일축이아닌다차원부분공간에분산되어있음을의미한다.

3.3 은닉상태 vs SAE 의전이성능

대부분의교차도메인전이방향에서은닉상태가 SAE 보다우수하다 (Gemma IC→SM: +0.247; SM→MW: +0.101; LLaMA SM→IC: +0.064). SAE 희소화 (sparsification) 는교차도메인일관성을잃을수있으며, 이는 BK 신호가희소분해가버리는분산된저진폭활성화에부분적으로의존함을시사한다.

3.4 RQ2 요약

교차도메인전이는두모델모두에서성공한다 (AUC 0.58–0.93, 모두 p=0.000). MW 가가장강력한허브패러다임이다. 직교가중치벡터에도불구하고공유저차원부분공간이 BK 를포착한다. BK 인코딩은심층에서도박도메인간에일반화된다.

4 RQ3: 베팅조건이바뀌어도 BK 패턴이유지되는가?

4.1 교차베팅유형전이 (F1)

고정베팅게임에서만훈련된 BK 분류기를가변베팅게임에적용하며, 그반대도수행한다.

Table 8: LLaMA IC 은닉상태전이

층	Fix→Var AUC	Var→Fix AUC	양방향 p
L8	0.872	0.842	0.000
L12	0.772	0.927	0.000
L22	0.736	0.912	0.000
L30	0.819	0.911	0.000

Table 9: Gemma IC SAE 전이

층	Fix→Var AUC	Var→Fix AUC	양방향 p
L18	0.808	0.726	0.000
L30	0.902	0.696	0.000
L10	NS	NS	—

LLaMA 에서는모든층과양방향모두 p=0.000 을산출한다. Var→Fix 전이 (0.84–0.93) 가 Fix→Var (0.74–0.87) 보다일관되게강한데, 이는가변게임이고정 BK 영역을포괄하는더넓은활성화공간을탐색하기때문일수있다. Gemma 에서는심층 (L30: Fix→Var 0.902) 이성공하는반면, 얕은층 (L10) 은실패한다—교차조건전이가심층표상을요구한다는일반적패턴과일치한다. Gemma IC 에는가변 BK 사례가 14 개뿐이어서, Gemma 특정베팅유형분석의통계적검정력이제한됨에유의한다.

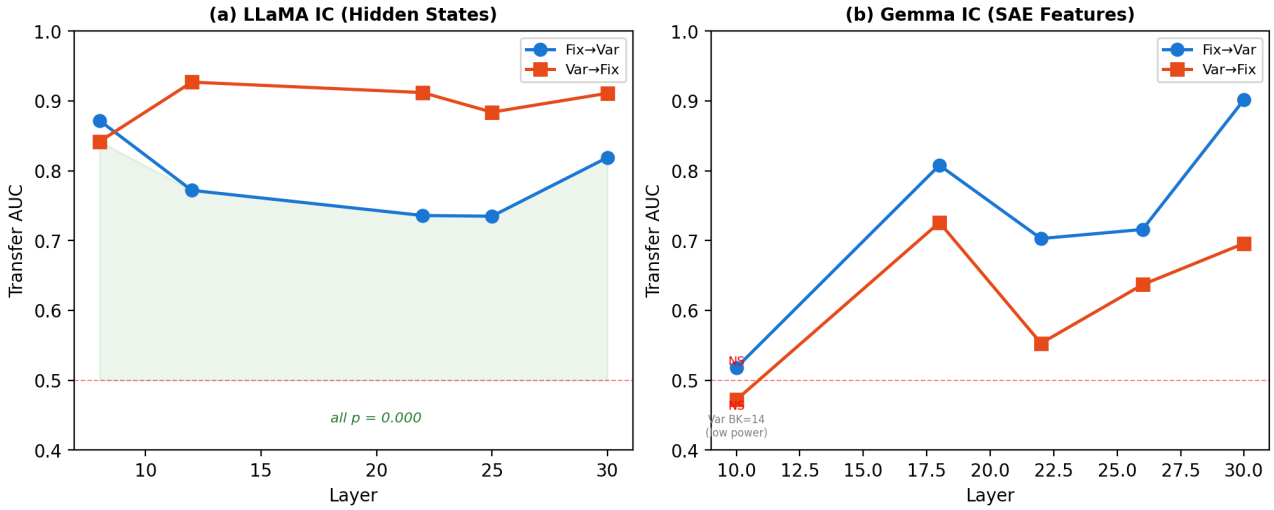

Figure 3: 교차베팅유형전이. (a) LLaMA: 모든층, 양방향, 모두 p=0.000. (b) Gemma SAE: 심층성공; L10 실패.

4.2 방향코사인과공통특징

가변 BK 방향과고정 BK 방향간의코사인유사도 (cosine similarity) 는보완적증거를제공한다. LLaMA IC 는모든은닉상태층에서 cos $>$ 0.81 이고, SAE 수준에서 cos 0.77–0.85 이다. Gemma IC 는얕은층의음수에서 L30 의 cos $\sim$0.39 로수렴한다—가변 BK 표본크기 (n=14) 가작아약한수치를보인다.

SAE L22 에서 415 개 LLaMA 특징 (및 35 개 Gemma 특징) 이두베팅조건모두에서 $d \geq 0.3$ 이고동일부호를보인다. 촉진/억제의균형비율 (LLaMA: 213/202) 은 §2.2 의보편적뉴런구조를반영한다.

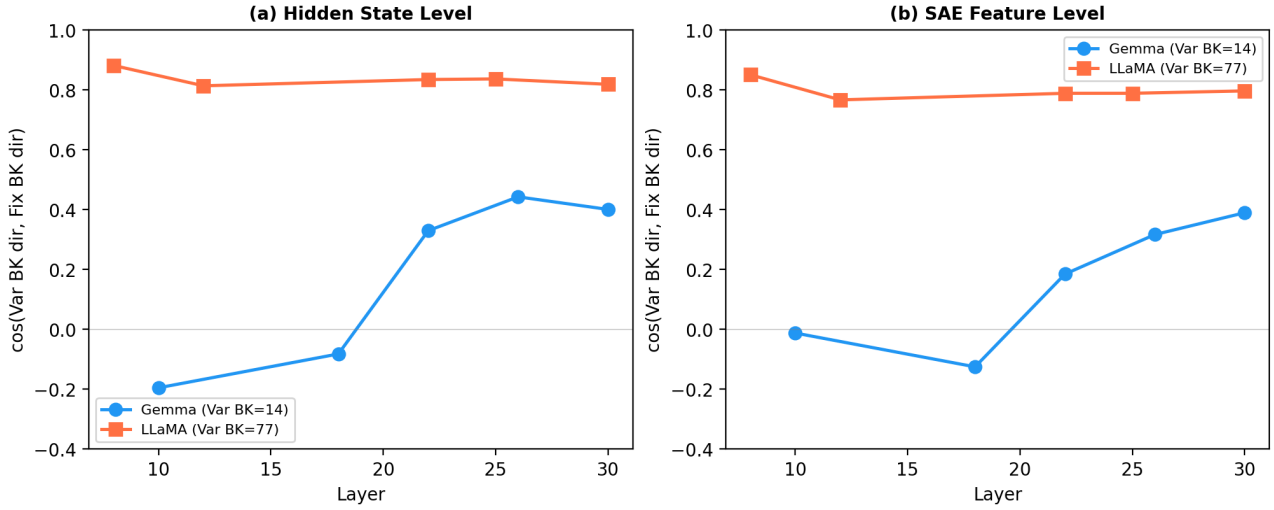

Figure 4: 가변/고정방향코사인: (a) 은닉상태, (b) SAE 수준. LLaMA cos>0.77 (모든층); Gemma 는심층에서수렴.

4.3 G-프롬프트와베팅제약효과

G(목표설정) 프롬프트는두모델모두에서활성화를 BK 방향으로이동시킨다 (cos = +0.85 Gemma SM, +0.63 LLaMA SM, L22). 베팅제약 (c10→c70) 은 BK 확률에선형으로매핑된다 (Gemma r=0.979, LLaMA r=0.987; 단 n=4 데이터포인트로이선형주장의강도가제한됨에유의). 이관찰들은 BK 표상이이진적 BK/Safe 구분이아닌연속적위험크기 (continuous risk magnitude) 를인코딩함을시사한다.

4.4 RQ3 요약

F1 교차베팅유형전이분석은고정과가변베팅조건이심층에서동일한기저 BK 표상을공유한다는직접적증거를제공한다. 방향코사인, 공통특징, G-프롬프트정렬이모두같은방향을가리킨다. BK 인코딩은두모델모두에서고정/가변조작에강건하다.

---

5 NMT 논문 §3.2 에대한함의

논문의 §3.2 는활성화패칭 (activation patching) 을통해 LLaMA SM 에서 112 개의인과적특징을식별하며, 안전특징은 L4–L19 에, 위험특징은 L24+ 이상에위치한다. 본분석은그단일모델, 단일도메인발견을세가지방향으로확장한다:

교차모델: Gemma 는거의동일한 BK 분류를달성하고 (0.976 vs 0.974) 동일한균형촉진/억제뉴런구조를보인다. 112 개인과적특징은 LLaMA 고유가아닌두아키텍처모두에존재하는속성을반영할가능성이높다.

교차도메인: BK 분류기가 IC, SM, MW 간에 AUC 최대 0.932 로전이된다. 요인분해는특징의 65–76% 가패러다임과무관하게 BK 를인코딩함을보여준다. SM 에서식별된인과적특징은다른도박도메인으로일반화될가능성이높다.

교차조건: 교차베팅유형전이 (AUC 0.74–0.93) 는 BK 표상이고정/가변조작에강건함을입증한다—이조작은논문의핵심행동발견 (가변베팅이파산을증가시킴) 을생성하는것과동일하다. 행동결과가발산하더라도신경표상은안정적으로유지된다.

인과적증거: L22 에서의방향조향이유의한용량-반응을생성하며 (Spearman ρ=0.927, p=0.003), 분류를통해식별된 BK 방향벡터가도박행동에인과적영향을미침을확인한다. 이는 V10 의상관적증거와논문의활성화패칭결과사이의간극을연결한다.

---

6 강건성검증

본절은 §2–§4 의분류결과가특정 PCA 차원수나분류기알고리즘선택의인위적산물이아님을검증한다. PCA 차원민감도와분류기비교의두분석으로이를다룬다.

6.1 PCA 차원민감도

본분석의목적은보고서전반에사용된 PCA=50 이강건한선택인지, 아니면결과를왜곡하는국소최적값 (local optimum) 인지를판별하는것이다. 6 개 PCA 차원 {10, 20, 50, 100, 200, Full (PCA 미적용)} 을 6 개모델–패러다임조합전체에서검정했다.

Table 10: PCA 차원민감도: PCA=50 vs Full (PCA 미적용) AUC

데이터셋	PCA=50	Full	50 에서포화?
Gemma SM	0.9755	0.9600	예
Gemma IC	0.9568	0.9635	예
Gemma MW	0.9658	0.9132	아니오 (PCA50 > Full)
LLaMA SM	0.9607	0.9631	예
LLaMA IC	0.9428	0.9195	아니오 (PCA50 > Full)
LLaMA MW	0.9590	0.9561	예

6 개데이터셋중 4 개에서 AUC 가 PCA=50 이전또는그지점에서포화되어, 추가차원이의미있는판별정보를기여하지않는다. 나머지 2 개데이터셋—Gemma MW 와 LLaMA IC—에서는 PCA=50 이전체차원표상보다우수하다. 이두데이터셋은각모델에서가장작은 BK 표본크기를가지며 (Gemma MW: n=54, LLaMA IC: n=142), 고차원특징공간이과적합에가장취약한경우이다. PCA 차원축소는이러한저-n 환경에서암묵적정규화기 (implicit regularizer) 로작용한다.

전체패턴은 PCA=50 이강건한기본값임을확인한다: 검정한모든데이터셋에서전체차원성능과일치하거나이를초과한다.

6.2 분류기비교

본분석의목적은 BK 표상이선형분리가능한지, 아니면비선형분류기가추가신호를추출하는지를판별하는것이다. PCA=50 에서세분류기를비교했다: 로지스틱회귀 (LR), 다층퍼셉트론 (MLP), RBF 커널 SVM(SVM-RBF).

Table 11: 분류기비교: PCA=50 에서의 AUC

데이터셋	LR	MLP	SVM-RBF	최대차이
Gemma SM	0.974	0.972	0.979	0.007
Gemma IC	0.956	0.954	0.956	0.002
Gemma MW	0.968	0.961	0.967	0.007
LLaMA SM	0.961	0.961	0.961	0.000
LLaMA IC	0.940	0.945	0.942	0.005
LLaMA MW	0.959	0.956	0.959	0.003

6 개데이터셋모두세분류기간최대 AUC 차이가 0.01 미만이다. 특정분류기가일관되게우세하지않는다. Table 11 은 BK 와 Safe 활성화상태가 PCA 축소공간에서선형분리가능함을입증한다: 비선형결정경계 (MLP, SVM-RBF) 는선형초평면 (로지스틱회귀) 에비해체계적이점을제공하지않는다.

6.3 강건성요약

PCA=50 은대부분의데이터셋에서 AUC 를포화시키고, 저-n 데이터셋에서과적합을방지하는강건한선택이다. 로지스틱회귀는 BK 분류에충분하며, 이는 BK 표상이선형분리가능하기때문이다. 이결과들은 §2–§4 의발견이파이프라인하이퍼파라미터의인위적산물이아님을확인한다.

---

7 인과적검증: BK 방향조향

V10 은두모델이 BK 를 1,334 개 (LLaMA) 및 600 개 (Gemma) 의보편적뉴런을통해인코딩하며, 높은분류 AUC 와교차도메인전이를보임을확립했다. 그러나 V10 의모든증거는상관적이다. 본절은 BK 방향벡터가도박행동을인과적으로통제하는지를검정한다.

7.1 뉴런수준제거 (영결과)

본분석의목적은특정뉴런이 BK 행동을구동한다는가장단순한인과적가설을검정하는것이다. §2.2 에서식별한 104 개강한촉진뉴런과 89 개강한억제뉴런 (LLaMA, L22) 에영제거 (zero ablation) 를적용했다. 각조건은 50 개 SM 게임에서검정되었다.

어떤조건도유의한행동변화를보이지않았다 (Fisher 정확검정, 모든 $p > 0.5$). 무작위뉴런통제 (동일수의무작위선택뉴런) 도효과가없었다. 이영결과는 BK 행동이개별뉴런에집중되어있다는가설을기각한다. 대신, §2.2 에서식별된균형촉진/억제구조는 BK 가전체활성화공간에걸친분산방향 (distributed direction) 으로인코딩됨을시사한다.

7.2 방향조향방법

BK 방향벡터는 L22 에서평균 BK 은닉상태와평균 Safe 은닉상태의차이로정의되며, LLaMA 활성화공간에서 4,096 차원벡터를산출한다. 이벡터를스케일링계수 $\alpha \in \{-2, -1, -0.5, 0, 0.5, 1, 2\}$ 로 L22 의잔차스트림에추가했다. 음의 α 는표상을 BK 에서멀어지게 (Safe 방향으로) 밀고, 양의 α 는 BK 방향으로민다. 각조건은 50 개 SM 게임에서검정했다. 무작위방향통제 (단위노름무작위벡터) 를 α=1.0 에서검정했다.

7.3 조향결과

Table 12: BK 방향조향 (LLaMA L22, SM, 조건당 n=50)

Alpha	중단율	BK 율
−2.0	0.660	0.340
−1.0	0.520	0.480
−0.5	0.580	0.420
0 (기준선)	0.520	0.480
+0.5	0.500	0.500
+1.0	0.480	0.520
+2.0	0.480	0.520
무작위방향 (α=1)	0.660	0.340

Table 12 는조향크기와 BK 율사이의단조적관계를보여준다. α 가 -2 에서 $+2$ 로증가함에따라 BK 율이 34% 에서 52% 로증가한다.

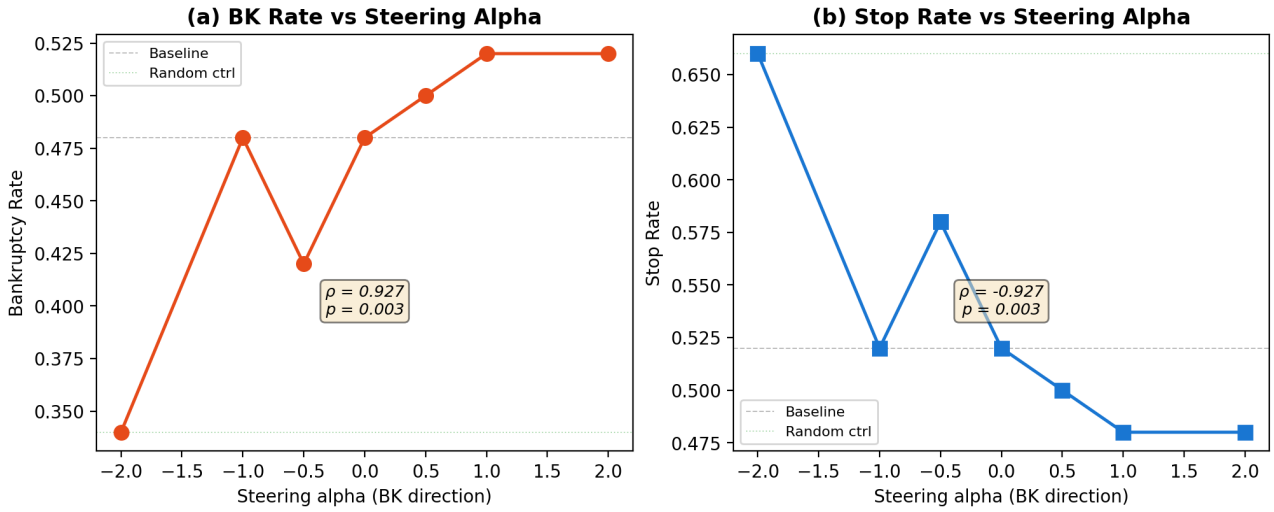

Figure 5: BK 방향조향용량-반응. (a) BK 율이 α 와단조적으로증가 (Spearman ρ=0.927, p=0.003). (b) 중단율이대응적으로감소. 점선 = 기준선; 점점선 = α=1 에서의무작위방향통제.

Fig. 5 해석: 용량-반응곡선은 BK 방향벡터가도박행동에인과적영향을미침을확인한다. 패널 (a): BK 방향으로밀면 (양의 α) 파산이증가하고, 반대방향으로밀면 (음의 α) 중단이증가한다. 관계는단조적이다 (Spearman ρ=0.927, p=0.003). 패널 (b): 중단율이이패턴을반영한다. 무작위방향통제 (점점선) 는단일 α 값에서높은중단율을보이지만, BK 방향만이 7 개 α 값에걸친점진적용량-반응을보여준다.

7.4 무작위방향통제와주의사항

α=1.0 에서의무작위방향통제는중단율 0.660, BK 율 0.340 을생성하며, 이는 α=-2.0 에서의 BK 방향과 크기가비슷하다. 이는잔차스트림에대한임의의교란이보수적행동 (중단) 을증가시키는경향이있음을나타내며, 매니폴드밖 (off-manifold) 교란이모델의기본행동패턴을방해하기때문일것이다.

BK 방향조향과무작위교란사이의결정적차이는 **용량-반응패턴**이다. BK 방향조향은 7 개 α 값에걸쳐단조적 α–BK 관계를생성한다 (ρ=0.927, p=0.003): 더양의 α 가더많은파산을산출한다. 무작위방향은단일 α 값 (α=1.0) 에서만검정되었으므로, 용량-반응을입증하거나반증할수없다. 방향특이성을완전히확립하려면, 무작위방향통제를여러 α 값에서검정해야한다. 무작위방향조향도비슷한기울기의단조적용량-반응을생성한다면, BK 방향은고유하게유익하지않을수있다. 예상대로무작위방향이평탄하거나비단조적프로필을생성한다면, 용량-반응패턴은 BK 방향에특이적이다.

7.5 상관적증거와인과적증거의연결

조향결과는세수준의증거를연결한다:

1. **상관적** (§2–§4): BK 와 Safe 상태가분류가능하고 (AUC $>$ 0.95), 도메인간전이되며 (AUC 0.58–0.93), 저차원부분공간을공유한다.
2. **뉴런수준인과적** (§7.1): 개별뉴런제거가효과를보이지않아, 희소인과메커니즘을기각한다.
3. **방향수준인과적** (§7.3): BK 방향벡터가유의한용량-반응을생성하며 (p=0.003), 분산 BK 표상의인과적영향을확인한다.

상관적분류에서인과적조향으로의이진행은해석틀을검증한다: BK 는도박행동을예측하고통제하는분산적, 방향적표상이다.

7.6 인과적검증요약

뉴런수준제거는영결과를산출하여, BK 가특정뉴런에집중되지않고분산되어있음을확인한다. 방향수준조향은단조적용량-반응을생성하며 (Spearman ρ=0.927, p=0.003), BK 방향의도박행동에대한인과적영향을확립한다. 무작위방향통제주의사항—임의교란도행동을변화시킨다는점—은다중-α 검정으로해결해야한다. 용량-반응패턴이방향특이성의핵심증거이다.

---

8 한계

1. **교차모델및교차도메인주장의상관적증거.** 방향조향을통한인과적검증은 LLaMA SM 에서만수행되었다 (§7). 교차모델 (Gemma) 및교차도메인 (IC, MW) 인과적검증은미완이다.
2. **표본크기불균형.** Gemma IC 는가변 BK 사례가 14 개뿐이어서, Gemma 베팅유형분석의검정력이심각하게제한된다. Gemma MW 는 54 개 BK 사례를가진다. LLaMA MW 는 2,426 개 BK (75.8%)—이높은기저율에서는사소한분류기도잘수행하며, 균형클래스가중치가부분적으로완화하지만보완지표 (균형정확도, F1) 가주장을강화할것이다.
3. **층범위.** LLaMA 은닉상태는 32 개중 5 개층 (L8, L12, L22, L25, L30) 에서추출된다. 이체크포인트사이의층별현상을놓칠수있다.
4. **베팅제약선형성.** r=0.979/0.987 선형매핑은 4 개데이터포인트 (c10, c30, c50, c70) 에서만계산된다. df=2 이면무작위관계도빈번히선형으로나타난다.
5. **공통 BK 특징.** 415 개공통특징 ($d\geq$0.3, 두베팅유형모두동일부호) 은순열귀무비교가없다. 우연히이기준을충족하는특징의기대수가계산되지않았다.
6. **다중비교.** FDR 보정은개별분석내에서적용되지만, 전체분석세트에걸쳐적용되지않는다. 효과크기를주요증거로취급해야한다.
7. **두모델만검정.** 다른아키텍처 (예: Qwen, Mistral) 로의일반화는검정되지않았다.
8. **조향무작위통제주의사항.** α=1 에서의무작위방향교란이 α=−2 에서의 BK 방향과비슷한크기의행동변화를생성했다. 용량-반응의방향특이성은무작위방향을여러 α 값에서검정하여 BK 방향이무작위보다더강한단조적관계를생성함을확인해야한다.
9. **조향 n=50.** 각조향조건은 50 개게임에서검정되었다. 더큰 n 이용량-반응곡선의정밀도를개선하고, 중간 α 값에서의더작은효과크기탐지를가능하게할것이다.

---

9 향후과제

1. **다중알파무작위방향통제**: 무작위방향을 $\alpha \in \{-2, -1, -0.5, 0.5, 1, 2\}$ 에서검정하여, BK 방향이무작위교란보다더강한용량-반응을생성하는지확인한다.
2. **다중층조향**: L22 + L25 + L30 동시조향으로다중층개입이용량-반응효과를증폭하는지검정한다.
3. **Gemma 조향복제**: BK 방향조향을 Gemma 에적용하여교차모델인과적일반화를검정한다.
4. **415 개공통특징의순열귀무**: 레이블순열하에서두베팅유형모두 $d\geq$0.3 인특징의기대수를계산하여, 415 가우연을초과하는지확인한다.